ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
**TRƯỜNG ĐẠI HỌC BÁCH KHOA**
**KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH**




**BÀI TẬP LỚN**
**MÔN KHO DỮ LIỆU VÀ HỆ HỖ TRỢ QUYẾT ĐỊNH**

# KHO DỮ LIỆU VÀ HỆ HỖ TRỢ QUYẾT ĐỊNH PHÂN TÍCH DOANH SỐ VÀ RỦI RO GIAO HÀNG

**Nhóm 11 - Lớp L01**
**Giảng viên hướng dẫn: Đỗ Thanh Thái**

| **Họ và tên** | **MSSV** |
|---|---|
| Võ Lâm Gia Bảo | 2310273 |
| Nguyễn Hữu Thiên Cường | 2310393 |
| Đặng Hải Sơn | 2312955 |

**TP. Hồ Chí Minh – 2026**

# Phân công nhiệm vụ

| STT | Họ và tên | MSSV | Nhiệm vụ | Đánh giá |
|---|---|---|---|---|
| 1 | Võ Lâm Gia Bảo | 2310273 | - Xây dựng data mart<br>- Huấn luyện mô hình ML<br>- Đánh giá kịch bản rủi ro | 100% |
| 2 | Nguyễn Hữu Thiên Cường | 2310393 | - Thiết kế kho dữ liệu<br>- Xây dựng quy trình ETL<br>- Kiểm tra, làm sạch dữ liệu | 100% |
| 3 | Đặng Hải Sơn | 2312955 | - Truy vấn phân tích OLAP<br>- Dựng dashboard Streamlit | 100% |

Bảng 1: Bảng phân công nhiệm vụ và đánh giá thành viên

**Đường dẫn báo cáo và mã nguồn dự án**

- **Mã nguồn:** github.com/nhtc2005/CO4031_Assignment_L01_Group11
- **Video thuyết trình:** drive.google.com/file/d/1k6Ek6Y3dr_Kv63DXEPRqzKbogfoyc3if/view?usp=sharing

# Mục lục

**1. Giới thiệu đề tài** ..... 1
1.1. Bối cảnh và lý do chọn đề tài ..... 1
1.2. Mục tiêu hệ thống ..... 1
1.3. Các câu hỏi nghiệp vụ cốt lõi ..... 1
1.4. Phạm vi đề tài và dữ liệu sử dụng ..... 2
**2. Phân tích dữ liệu nguồn và quy tắc làm sạch** ..... 2
2.1. Mô tả dữ liệu thô và phạm vi trích xuất ..... 2
2.2. Kết quả đánh giá hồ sơ dữ liệu nguồn ..... 2
2.3. Các vấn đề chất lượng dữ liệu phát hiện được ..... 3
2.4. Quy tắc làm sạch và chuẩn hóa dữ liệu ..... 4
**3. Thiết kế kho dữ liệu đa chiều** ..... 5
3.1. Mô hình hóa đa chiều và cấu trúc tổng thể ..... 5
3.2. Thiết kế các bảng dim ..... 6
3.3. Thiết kế các bảng fact ..... 6
3.4. Ràng buộc vật lý và tối ưu hóa truy vấn ..... 7
**4. Quy trình ETL** ..... 7
4.1. Kiến trúc quy trình xử lý dữ liệu ..... 7
4.2. Quy trình nạp dữ liệu tầng staging và kho dữ liệu ..... 8
4.3. Tự động hóa điều phối với Apache Airflow ..... 9
**5. Truy vấn OLAP và giao diện phân tích kinh doanh** ..... 10
5.1. Định nghĩa các chỉ số kinh doanh cốt lõi ..... 10
5.2. Thiết kế giao diện trên Streamlit ..... 10
5.3. Hạn chế ..... 11
**6. Thiết kế hệ hỗ trợ quyết định và mô hình dự báo** ..... 12
6.1. Kiến trúc hệ hỗ trợ quyết định ..... 12
6.2. Xác định mốc thời gian dự báo và các biến đặc trưng ..... 12
6.3. Huấn luyện mô hình và quy trình phân chia dữ liệu ..... 13
6.4. Thiết kế chức năng mô phỏng khả năng kiểm tra trên Streamlit ..... 13
**7. Kết quả thực nghiệm và đánh giá** ..... 14
7.1. Kết quả thực thi các tiến trình ETL và độ chính xác dữ liệu ..... 14
7.2. Đánh giá hiệu năng mô hình dự báo rủi ro ..... 15
7.3. Đánh giá kịch bản phân bổ nguồn lực kiểm tra ..... 16
**8. Hạn chế, hướng phát triển và kết luận** ..... 17
8.1. Những kết quả đạt được của đề tài ..... 17
8.2. Hạn chế còn tồn tại ..... 17
8.3. Hướng phát triển trong tương lai ..... 18

8.4. Kết luận ..... 19

# 1. Giới thiệu đề tài

## 1.1. Bối cảnh và lý do chọn đề tài

Trong sự phát triển mạnh mẽ của ngành thương mại điện tử hiện nay, việc quản lý và tối ưu hóa quy trình vận chuyển đóng vai trò then chốt đối với sự hài lòng của khách hàng và uy tín của sàn giao dịch. Olist, một nền tảng thương mại điện tử lớn tại Brazil, phải xử lý hàng trăm nghìn đơn hàng kết nối giữa người mua và người bán trên khắp cả nước. Tuy nhiên, do đặc thù địa lý rộng lớn cũng như sự khác biệt về năng lực xử lý của từng đối tác vận chuyển, tình trạng giao hàng trễ so với thời gian dự kiến vẫn xảy ra.

Để giải quyết thách thức này, việc chỉ dựa vào các báo cáo thống kê truyền thống là chưa đủ. Do đó, nhóm chúng em quyết định ứng dụng kiến trúc kho dữ liệu kết hợp với hệ hỗ trợ quyết định nhằm cung cấp góc nhìn toàn diện từ mức chiến lược đến mức vận hành. Hệ thống không chỉ giúp nhà quản lý phân tích các chỉ số kinh doanh cốt lõi mà còn tích hợp mô hình học máy để phát hiện sớm các đơn hàng có rủi ro giao trễ cao, từ đó tối ưu hóa việc phân bổ nguồn lực kiểm tra.

## 1.2. Mục tiêu hệ thống

Hệ thống được thiết kế hướng tới hai nhóm người dùng chính trong doanh nghiệp bao gồm các nhà quản lý kinh doanh và đội ngũ vận hành hoặc chăm sóc khách hàng. Đối với nhà quản lý kinh doanh, hệ thống cung cấp các báo cáo tổng quan về doanh thu, số lượng đơn hàng, giá trị trung bình đơn hàng cũng như biến động của tỷ lệ giao trễ theo thời gian. Bên cạnh đó, các công cụ phân tích đa chiều cho phép người dùng khai thác sâu hơn về đóng góp doanh thu theo từng danh mục sản phẩm hoặc từng khu vực địa lý.

Đối với đội ngũ vận hành, mục tiêu là hỗ trợ lựa chọn đơn hàng cần ưu tiên rà soát khi nguồn lực có hạn. Hệ thống cho phép thay đổi năng lực kiểm tra và so sánh mức bao phủ đơn trễ với lựa chọn ngẫu nhiên cùng số lượng. Việc này giúp đội ngũ vận hành có thể xác minh tiến độ với người bán hoặc đơn vị vận tải và cân nhắc thông báo về tình trạng đơn hàng cho khách hàng.

## 1.3. Các câu hỏi nghiệp vụ cốt lõi

Để đáp ứng nhu cầu của các nhóm đối tượng sử dụng, hệ thống được thiết kế nhằm giải quyết bốn câu hỏi nghiệp vụ chính sau:

- Biến động về doanh thu và tổng số lượng đơn hàng của sàn diễn ra như thế nào theo thời gian?
- Những danh mục sản phẩm và bang nào của khách hàng đang đóng góp tỷ trọng doanh thu lớn nhất cho hệ thống?

- Tỷ lệ giao hàng trễ so với cam kết biến động như thế nào qua các tháng trong năm?
- Trong nhóm đơn hàng lịch sử được chấm điểm, những đơn nào nên được ưu tiên kiểm tra và mức năng lực lựa chọn bao phủ được bao nhiêu đơn từng giao trễ?

### 1.4. Phạm vi đề tài và dữ liệu sử dụng

Dữ liệu sử dụng trong đề tài này được trích xuất từ bộ dữ liệu Brazilian E-Commerce Public Dataset by Olist. Bộ dữ liệu chứa thông tin chi tiết của 99,441 đơn hàng được thực hiện từ năm 2016 đến năm 2018 tại Brazil. Hệ thống được triển khai trên nền tảng cơ sở dữ liệu PostgreSQL để lưu trữ kho dữ liệu, công cụ Apache Airflow đảm nhiệm quy trình tự động hóa ETL, và giao diện ứng dụng Streamlit đóng vai trò là bảng điều khiển tương tác người dùng.

Do đặc thụ bài toán được xây dựng trên bộ dữ liệu tĩnh trong quá khứ, mô hình học máy Logistic Regression được huấn luyện ngoại tuyến trên tập dữ liệu lịch sử để tính toán xác suất rủi ro. Kết quả dự báo được lưu trữ cố định vào kho dữ liệu nhằm phục vụ cho chức năng mô phỏng khả năng kiểm tra đơn hàng tại giao diện vận hành.

## 2. Phân tích dữ liệu nguồn và quy tắc làm sạch

### 2.1. Mô tả dữ liệu thô và phạm vi trích xuất

Dữ liệu nguồn được trích xuất từ bộ dữ liệu thương mại điện tử công khai của Olist, lưu trữ dưới dạng các tệp CSV thô tại thư mục nguồn. Nhóm tiến hành khảo sát toàn bộ 9 tệp dữ liệu thô và quyết định đưa 7 tệp dữ liệu vào phạm vi xử lý của kho dữ liệu, bao gồm các bảng về đơn hàng, khách hàng, chi tiết đơn hàng, sản phẩm, người bán, đánh giá và bảng dịch danh mục sản phẩm.

Hai tệp dữ liệu về phương thức thanh toán và vị trí địa lý chi tiết được loại bỏ khỏi phạm vi phiên bản này do không phục vụ trực tiếp cho 4 câu hỏi nghiệp vụ đã đề ra. Việc giới hạn phạm vi giúp tối ưu hóa cấu trúc kho dữ liệu và tập trung vào mục tiêu phân tích doanh thu cũng như đánh giá rủi ro giao hàng trễ.

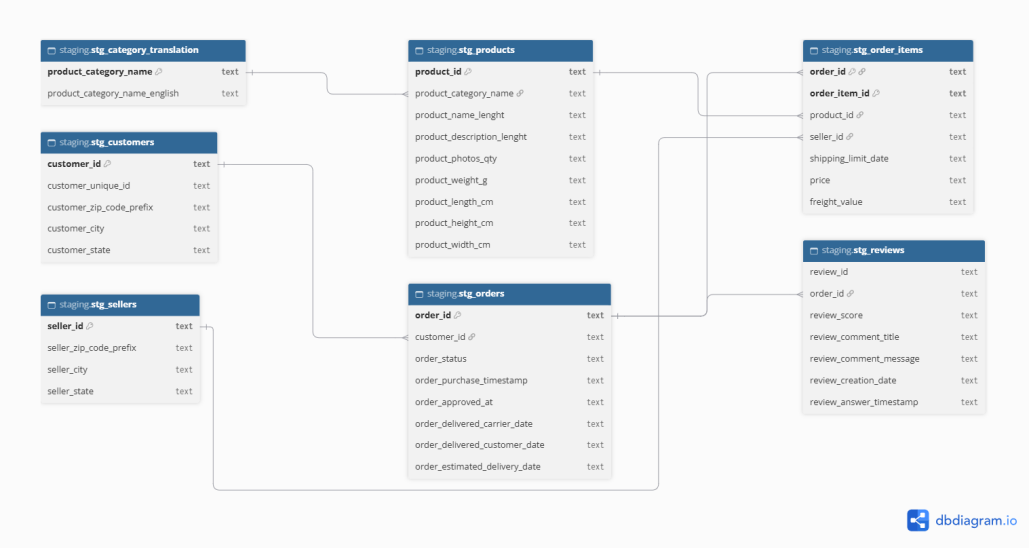
### 2.2. Kết quả đánh giá hồ sơ dữ liệu nguồn

Do các tệp dữ liệu thô dạng CSV không có các ràng buộc quan hệ cứng, nhóm đã xây dựng kịch bản kiểm tra tự động chạy trực tiếp trên các tệp CSV gốc để đánh giá cấu trúc, tính duy nhất của các trường định danh và tính toàn vẹn tham chiếu giữa các tệp trước khi nạp vào tầng lưu trữ trung gian staging. Tất cả các bảng tại tầng staging được thiết kế để giữ nguyên vẹn dữ liệu thô dạng chuỗi ký

tự và không thiết lập các ràng buộc khóa cứng nhằm phục vụ mục đích lưu trữ trung gian và truy vết sự cố. Kết quả khảo sát hồ sơ dữ liệu thô được tổng hợp chi tiết trong Bảng 2.1.

Bảng 2.1: Tổng hợp kết quả khảo sát các tệp dữ liệu nguồn Olist.

| Tệp dữ liệu thô | Số lượng dòng | Trường định danh | Kết quả khảo sát tính duy nhất |
|---|---|---|---|
| olist_orders_dataset.csv | 99,441 | order_id | Duy nhất, không có giá trị rỗng |
| olist_customers_dataset.csv | 99,441 | customer_id | Duy nhất, phân biệt với customer_unique_id |
| olist_order_items_dataset.csv | 112,650 | (order_id, order_item_id) | Tổ hợp định danh duy nhất |
| olist_products_dataset.csv | 32,951 | product_id | Duy nhất, có 610 dòng rỗng danh mục |
| olist_sellers_dataset.csv | 3,095 | seller_id | Duy nhất, phủ trên 23 bang |
| olist_order_reviews_dataset.csv | 99,224 | review_id | Không duy nhất; 1,603 dòng liên quan đến các mã được tái sử dụng |
| product_category_name_translation.csv | 71 | product_category_name | Phủ hầu hết danh mục tiếng Bồ Đào Nha |




Hình 2.1: Sơ đồ quan hệ logic giữa các thực thể dữ liệu nguồn. Các ký hiệu khóa và liên kết không biểu thị ràng buộc PK/FK được khai báo vật lý tại tầng staging.

## 2.3. Các vấn đề chất lượng dữ liệu phát hiện được

Mặc dù không phát hiện bản ghi mồ côi trong các quan hệ thực thể chính, quá trình phân tích nội dung các tệp CSV gốc vẫn ghi nhận một số vấn đề chất lượng dữ liệu cần được xử lý hoặc đánh dấu trong quá trình nạp kho dữ liệu:

– Bảng đánh giá tồn tại 789 mã review_id được tái sử dụng cho các đơn hàng

khác nhau, liên quan đến 1,603 dòng dữ liệu. Với mỗi mã được tái sử dụng, nội dung đánh giá, điểm số và các mốc thời gian giống nhau; tuy nhiên, các dòng không trùng lặp hoàn toàn vì khác order_id. Do đó, không thể loại bỏ bản ghi chỉ dựa trên review_id.

- Bảng sản phẩm có 610 dòng thiếu tên danh mục và các thuộc tính mô tả, cùng 2 dòng thiếu trọng lượng và kích thước. Ngoài ra, có 13 dòng sản phẩm thuộc 2 danh mục tiếng Bồ Đào Nha không tìm thấy tên dịch tương ứng trong bảng dịch tiếng Anh. Có 4 sản phẩm ghi nhận trọng lượng bằng 0 gam.
- Phân tích chuỗi thời gian vận chuyển phát hiện 166 trường hợp thời điểm bàn giao cho đơn vị vận tải diễn ra trước thời điểm mua hàng, và 32 trường hợp thời điểm bàn giao lại diễn ra sau thời điểm khách hàng nhận hàng. Hai nhóm có thể chồng lặp nên không cộng trực tiếp để xác định tổng số đơn bất thường.
- Trường dữ liệu thành phố của người bán chứa một số biến thể chuỗi ký tự do xuất hiện khoảng trắng thừa ở giữa các từ.

### 2.4. Quy tắc làm sạch và chuẩn hóa dữ liệu

Dựa trên các phát hiện về chất lượng dữ liệu thô, nhóm áp dụng các quy tắc chuyển đổi và làm sạch trong quá trình nạp dữ liệu từ tầng trung gian staging vào kho dữ liệu chính thức:

- Tất cả các cột tại tầng staging được lưu dưới dạng TEXT, giữ nguyên toàn bộ bản ghi nguồn nhằm đảm bảo khả năng truy vết. Các trường CSV rỗng được biểu diễn bằng NULL theo quy tắc nạp dữ liệu. Việc chuyển đổi sang các kiểu TIMESTAMP, INTEGER và NUMERIC được thực hiện khi nạp vào kho dữ liệu.
- Đối với sản phẩm thiếu danh mục hoặc không tìm thấy bản dịch tiếng Anh, cột category_name_en trong bảng dw.dim_product nhận giá trị mặc định Unknown / untranslated. Danh mục nguồn vẫn được giữ lại để truy vết. Các thông số vật lý bằng 0 được chuyển thành NULL trong kho dữ liệu và đánh dấu bằng cờ has_physical_anomaly. Giá trị âm hoặc không đúng định dạng bị từ chối tại bước kiểm tra trước chuyển đổi; các giá trị vật lý được lưu phải dương hoặc là NULL.
- Đối với bất thường về thứ tự các mốc thời gian, hệ thống không tự ý sửa thời gian nguồn. Cờ has_temporal_anomaly được đặt thành TRUE để nhận diện các đơn có mốc thời gian mâu thuẫn. Thời điểm bàn giao cho đơn vị vận tải chỉ được dùng trong quá trình kiểm tra bất thường, không được lưu thành một vai trò ngày riêng trong kho dữ liệu.

– Dữ liệu đánh giá được giữ nguyên tại staging. Khi nạp kho dữ liệu, hệ thống giữ một bản ghi cho mỗi cặp (order_id,review_id), ưu tiên bản ghi có review_answer_timestamp mới nhất, sau đó là review_creation_date mới nhất. Các bản ghi cùng review_id nhưng khác order_id vẫn được giữ. Sau đó, dữ liệu được tổng hợp theo từng đơn hàng thành điểm trung bình review_avg_score và số bản ghi review_record_count trước khi nạp vào dw.fact_delivery.
– Mã bang của khách hàng và người bán được loại bỏ khoảng trắng đầu cuối và chuẩn hóa thành chữ hoa với 2 ký tự mã bang Brazil. Tên thành phố được chuyển thành chữ thường, loại bỏ khoảng trắng đầu cuối và thu gọn khoảng trắng lặp lại ở giữa chuỗi; tên thành phố nguồn được giữ riêng để truy vết.

# 3. Thiết kế kho dữ liệu đa chiều

## 3.1. Mô hình hóa đa chiều và cấu trúc tổng thể

Trên cơ sở các câu hỏi nghiệp vụ và kết quả phân tích dữ liệu nguồn, nhóm thiết kế kho dữ liệu theo kiến trúc Fact Constellation, trong đó mỗi bảng fact liên kết với các bảng dim theo cấu trúc hình sao. Kho gồm hai bảng fact cho bán hàng và giao hàng, cùng bốn bảng dim thời gian, khách hàng, sản phẩm và người bán. Hai bảng dim thời gian và khách hàng được dùng chung bởi cả hai fact; sản phẩm và người bán chỉ liên kết với bảng fact bán hàng.




Hình 3.1: Sơ đồ ERD mô hình kho dữ liệu đa chiều

Mô hình tách biệt hai mức chi tiết (grain): fact_sales có một dòng cho mỗi đơn vị sản phẩm trong đơn hàng, còn fact_delivery có một dòng cho mỗi đơn

hàng. Thiết kế này giúp tối ưu hóa hiệu năng truy vấn cho các báo cáo doanh thu chi tiết cũng như các phân tích về vận chuyển đơn hàng.

### 3.2. Thiết kế các bảng dim

Các bảng dim cung cấp ngữ cảnh phân tích cho các bảng fact. Ba bảng dim _customer, dim_seller và dim_product dùng khóa thay thế (surrogate key) kiểu BIGINT do kho dữ liệu sinh tự động. Riêng dim_date dùng khóa ngày có ý nghĩa dạng số nguyên YYYYMMDD, được suy ra trực tiếp từ ngày lịch. Thuộc tính cal endar_date là khóa tự nhiên và được ràng buộc duy nhất.

Bảng dim_date lưu trữ chi tiết các thuộc tính lịch từ ngày bắt đầu mua hàng đến ngày hứa giao dự kiến. Bảng sử dụng khóa chính date_key định dạng YYY YMMDD và cung cấp các thuộc tính phân tích như năm, quý, tháng, ngày trong tháng, thứ trong tuần, tên tháng, tên thứ và cờ xác định ngày cuối tuần. Bảng này đóng nhiều vai trò (role-playing dimension) trong hệ thống, bao gồm ngày đặt hàng, ngày phê duyệt, ngày giao thực tế và ngày hứa giao.

Bảng dim_customer lưu thông tin khách hàng và địa lý với khóa chính cust omer_key. customer_id được giữ lại với ràng buộc duy nhất, còn customer_uniq ue_id có thể lặp để nhận diện cùng khách hàng qua nhiều lần mua. Bảng có mã bưu chính, thành phố gốc, thành phố chuẩn hóa và mã bang 2 ký tự.

Bảng dim_seller lưu trữ thông tin của các đối tác bán hàng với khóa chính s eller_key và mã người bán gốc seller_id. Tương tự như bảng dim_customer, bảng này lưu giữ mã bưu chính, tên thành phố gốc, tên thành phố chuẩn hóa và mã bang để phục vụ phân tích vận chuyển liên bang.

Bảng dim_product lưu trữ thông tin thuộc tính và đặc tính vật lý của sản phẩm với khóa chính product_key và mã sản phẩm gốc product_id. Bảng chứa tên danh mục gốc tiếng Bồ Đào Nha, tên danh mục chuẩn hóa, tên danh mục tiếng Anh, độ dài tên, độ dài mô tả, số lượng ảnh và các thông số kích thước vật lý như trọng lượng, chiều dài, chiều cao, chiều rộng. Ngoài ra, bảng bổ sung hai cờ quản lý chất lượng dữ liệu là has_missing_category và has_physical_anomaly.

### 3.3. Thiết kế các bảng fact

Bảng fact_sales lưu trữ thông tin chi tiết từng đơn vị sản phẩm được bán. Khóa chính của bảng là khóa phức hợp kết hợp giữa order_id và order_item_id. Bảng liên kết với các bảng dim thông qua các khóa ngoại customer_key, product_ key, seller_key, purchase_date_key. Các thuộc tính đo lường bao gồm tiền hàng i tem_revenue và cước vận chuyển freight_value. Mốc thời gian hạn chót giao hàng cho đơn vị vận tải shipping_limit_timestamp cũng được lưu trữ tại đây.

Bảng fact_delivery lưu trữ thông tin vận chuyển và đánh giá ở mức tổng hợp đơn hàng với khóa chính order_id. Bảng liên kết với bảng dim_customer qua cus tomer_key và liên kết với bảng dim_date qua 4 khóa ngoại: purchase_date_key, approval_date_key, actual_delivery_date_key và estimated_delivery_date_ke y. Bảng lưu trữ các mốc thời gian chi tiết, trạng thái đơn hàng chuẩn hóa order_ status, cờ hợp lệ tính thời gian is_timeliness_eligible, cờ giao trễ is_late, số ngày chậm trễ delivery_delay_days và cờ mâu thuẫn thời gian has_temporal_anoma ly. Ngoài ra, kết quả gom nhóm đánh giá từ người dùng được tích hợp vào bảng thông qua hai trường điểm đánh giá trung bình review_avg_score và số lượng bản ghi đánh giá review_record_count.

Bảng 3.1: Tổng hợp cấu trúc các bảng trong kho dữ liệu

| **Tên bảng** | **Kiểu bảng** | **Khóa chính** | **Mức chi tiết** |
|---|---|---|---|
| dw.dim_date | Dimension | date_key | Một ngày lịch |
| dw.dim_customer | Dimension | customer_key | Một mã địa chỉ customer_id |
| dw.dim_seller | Dimension | seller_key | Một mã người bán seller_id |
| dw.dim_product | Dimension | product_key | Một mã sản phẩm product_id |
| dw.fact_sales | Fact | (order_id, order_ite m_id) | Một đơn vị sản phẩm trong đơn hàng |
| dw.fact_delivery | Fact | order_id | Một đơn hàng |

### 3.4. Ràng buộc vật lý và tối ưu hóa truy vấn

Kho dữ liệu được triển khai vật lý trên hệ quản trị cơ sở dữ liệu PostgreSQL. Tất cả các khóa chính và khóa ngoại đều được thiết lập các ràng buộc toàn vẹn dữ liệu chặt chẽ như PRIMARY KEY, FOREIGN KEY, NOT NULL và CHECK. Ràng buộc CHECK được áp dụng triệt để để đảm bảo tính hợp lệ của dữ liệu, chẳng hạn như kiểm tra các giá trị tiền hàng, cước phí và kích thước không âm, cũng như kiểm tra logic bắt buộc giữa cờ is_timeliness_eligible và trường is_late.

Để tối ưu hóa hiệu năng cho các truy vấn OLAP và các thao tác tổng hợp báo cáo, nhóm tạo các chỉ mục trên các cột khóa ngoại của các bảng fact. Việc đánh chỉ mục trên các trường như customer_key, product_key, seller_key giúp đẩy nhanh tốc độ thực hiện các phép JOIN và các thao tác truy vấn dữ liệu.

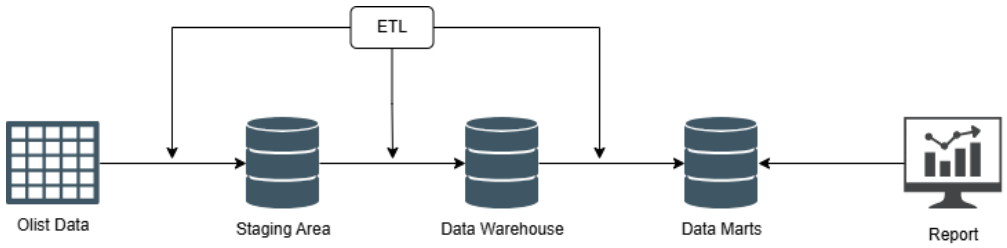
## 4. Quy trình ETL

### 4.1. Kiến trúc quy trình xử lý dữ liệu

Quy trình dữ liệu đi từ các tệp CSV thô qua ba tầng lưu trữ staging, kho dữ liệu và mart. Ba DAG trên Apache Airflow lần lượt thực hiện nạp và kiểm tra dữ liệu nguồn, chuyển đổi và xây dựng kho dữ liệu, rồi tạo bảng đặc trưng mart.orde

r_delivery_ml_features. Các DAG được kích hoạt thủ công theo thứ tự; Airflow điều phối các tác vụ bên trong từng DAG.

Sau ba DAG dữ liệu, người vận hành chạy riêng chương trình src/ml/train_model.py để huấn luyện và chấm điểm. Kết quả được lưu trong mart.order_late_risk, còn mô hình và metadata được lưu dưới thư mục models/.




Hình 4.1: Sơ đồ kiến trúc luồng dữ liệu ETL.

## 4.2. Quy trình nạp dữ liệu tầng staging và kho dữ liệu

Tác vụ nạp dữ liệu tầng staging được thực hiện bởi tiến trình olist_staging_pipeline. Tiến trình này đọc toàn bộ 7 tệp CSV thô được chọn trong phạm vi đề tài, nạp trực tiếp vào các bảng tương ứng trong schema staging. Tất cả các cột dữ liệu tại tầng staging đều được định dạng kiểu TEXT và giữ nguyên toàn bộ số lượng bản ghi thô mà không thực hiện loại bỏ trùng lặp, lọc hay chuyển đổi kiểu dữ liệu.

Tác vụ nạp kho dữ liệu chính thức được thực hiện bởi tiến trình olist_dw_pipeline. Tiến trình này đọc dữ liệu từ schema staging, thực hiện các bước biến đổi dữ liệu, ánh xạ khóa và nạp vào schema dw. Quá trình biến đổi bao gồm các thao tác chính sau:

- Kiểm tra đầu vào rồi chuyển các trường chuỗi sang TIMESTAMP, `NUMERIC` và INTEGER; các cờ BOOLEAN được suy ra từ điều kiện nghiệp vụ.
- Tạo khóa thay thế tự tăng cho các bảng dim dim_customer, dim_seller, dim_product và tạo khóa ngày date_key định dạng YYYYMMDD cho bảng dim_date.
- Gán Unknown / untranslated cho dw.dim_product.category_name_en khi thiếu danh mục hoặc bản dịch tiếng Anh, đồng thời giữ lại danh mục nguồn.
- Giữ một bản ghi theo quy tắc ưu tiên thời gian cho mỗi cặp (order_id,review_id), rồi tổng hợp điểm trung bình review_avg_score và số bản ghi review_record_count theo từng đơn hàng.
- Xác định tập đơn delivered có đủ mốc mua, giao thực tế và hứa giao, trong đó thời điểm giao không trước thời điểm mua. Chỉ với tập đủ điều kiện này, is_late và delivery_delay_days mới được tính bằng ngày lịch. Giao vào

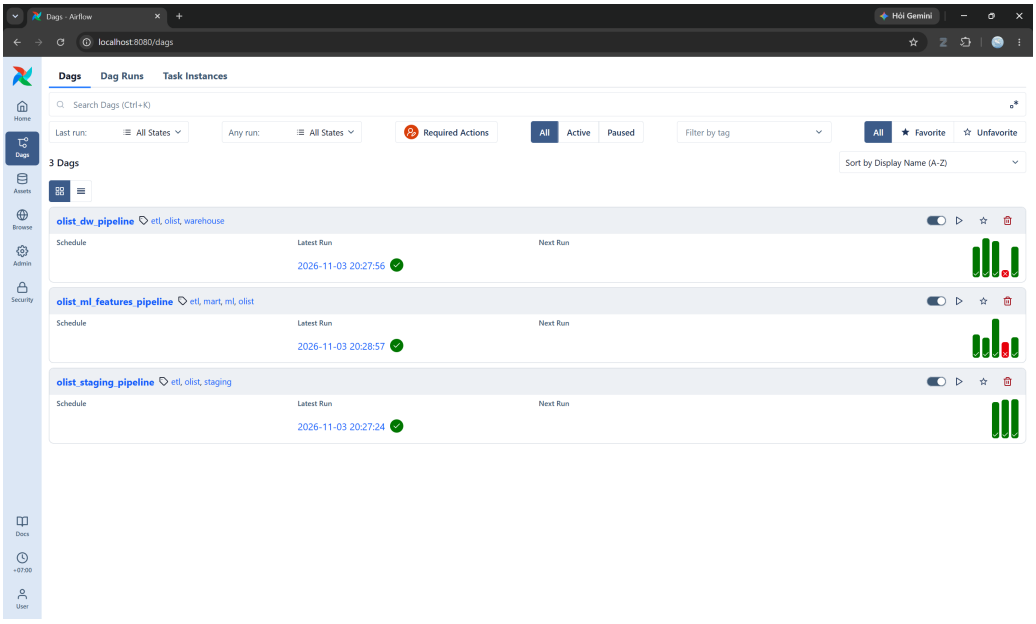
bất kỳ thời điểm nào trong ngày hứa giao vẫn là đúng hạn; hai đại lượng nhận NULL nếu đơn không đủ điều kiện.

– Chuyển thông số vật lý bằng 0 thành NULL và đánh dấu has_physical_anomaly; đầu vào vật lý âm hoặc sai định dạng bị từ chối ở bước kiểm tra trước chuyển đổi. Cờ has_temporal_anomaly đánh dấu thứ tự mốc thời gian mâu thuẫn mà không tự sửa thời gian nguồn.

Sau khi DAG xây dựng kho dữ liệu và bước kiểm tra của nó thành công, người vận hành kích hoạt olist_ml_features_pipeline. Tiến trình tổng hợp dòng hàng từ fact_sales về mức đơn, kết hợp fact_delivery và các bảng dim cần thiết để tạo mart.order_delivery_ml_features, mỗi đơn một dòng. Cờ đủ điều kiện và nhãn được giữ cạnh các đặc trưng để lựa chọn tập dữ liệu mô hình.

### 4.3. Tự động hóa điều phối với Apache Airflow

Các DAG sử dụng TaskFlow API với decorator @dag và @task để đóng gói tác vụ Python. Cả ba có cấu hình schedule=None, không có cơ chế tự kích hoạt DAG tiếp theo. Người vận hành chạy theo thứ tự olist_staging_pipeline → olist_dw_pipeline → olist_ml_features_pipeline, kiểm tra trạng thái thành công ở mỗi bước, rồi chạy riêng chương trình huấn luyện/chấm điểm. Chức năng tự động hóa hiện tại nằm ở việc thực thi và giám sát các tác vụ trong từng DAG.




Hình 4.2: Giao diện giám sát thực thi các tiến trình ETL trên Apache Airflow.

Việc theo dõi trạng thái thực thi được thực hiện trực tiếp trên giao diện web của Apache Airflow. Hệ thống cho phép truy xuất lịch sử chạy, thời gian thực thi của từng tác vụ và nhật ký chi tiết khi phát hiện sự cố, giúp nhóm dễ dàng khoanh vùng và xử lý lỗi phát sinh trong quá trình vận hành.

# 5. Truy vấn OLAP và giao diện phân tích kinh doanh

## 5.1. Định nghĩa các chỉ số kinh doanh cốt lõi

Để đảm bảo tính chính xác và nhất quán cho các báo cáo phân tích trên giao diện, nhóm tiến hành thống nhất công thức và phương pháp tính toán cho các chỉ số đo lường hiệu suất (KPI) chính trong hệ thống.

Doanh thu bán hàng được định nghĩa là tổng giá trị tiền hàng item_revenu e của các đơn hàng có trạng thái khác canceled. Cước vận chuyển freight_value được tách biệt khỏi doanh thu sản phẩm. Các đơn hàng bị hủy không được tính vào tổng doanh thu bán hàng nhưng vẫn được lưu trữ đầy đủ trong kho dữ liệu phục vụ mục đích kiểm toán.

Số lượng đơn hàng và giá trị trung bình đơn hàng (AOV - Average Order Value) được tính toán trên cùng một tập đơn hàng không bị hủy và có chứa ít nhất một sản phẩm. Chỉ số AOV được xác định bằng tổng doanh thu bán hàng chia cho tổng số lượng đơn hàng tương ứng trong cùng khoảng thời gian.

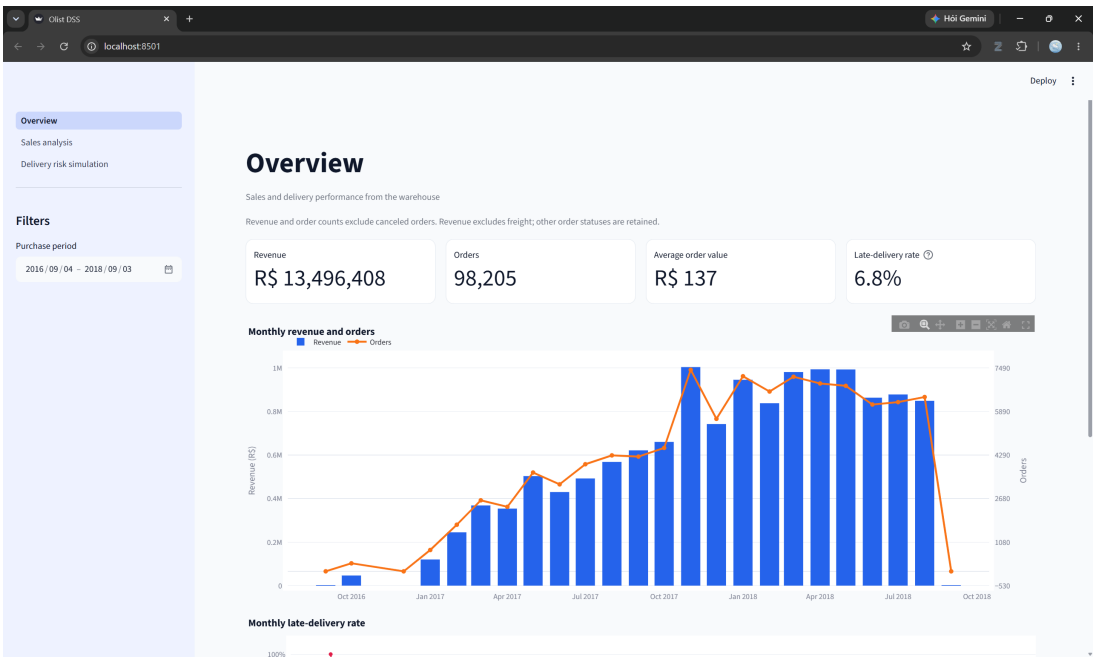
Doanh thu theo danh mục sản phẩm được tính dựa trên giá trị tiền hàng của các sản phẩm thuộc danh mục đó. Do một đơn hàng có thể chứa nhiều sản phẩm thuộc các danh mục khác nhau, tổng số đơn hàng phân theo danh mục có thể có sự chồng chéo và không được cộng dồn trực tiếp.

Tỷ lệ giao hàng trễ được tính bằng số đơn hàng giao trễ thực tế chia cho tổng số đơn hàng hợp lệ tính thời gian (is_timeliness_eligible = TRUE). Mẫu số này chỉ bao gồm các đơn hàng đã giao thành công và có đầy đủ mốc thời gian hợp lệ, hoàn toàn độc lập với mẫu số tính doanh thu bán hàng. Các chỉ số này được tổng hợp thông qua các truy vấn JOIN giữa bảng fact_sales, fact_delivery với các bảng dim_date, dim_product và dim_customer.

## 5.2. Thiết kế giao diện trên Streamlit

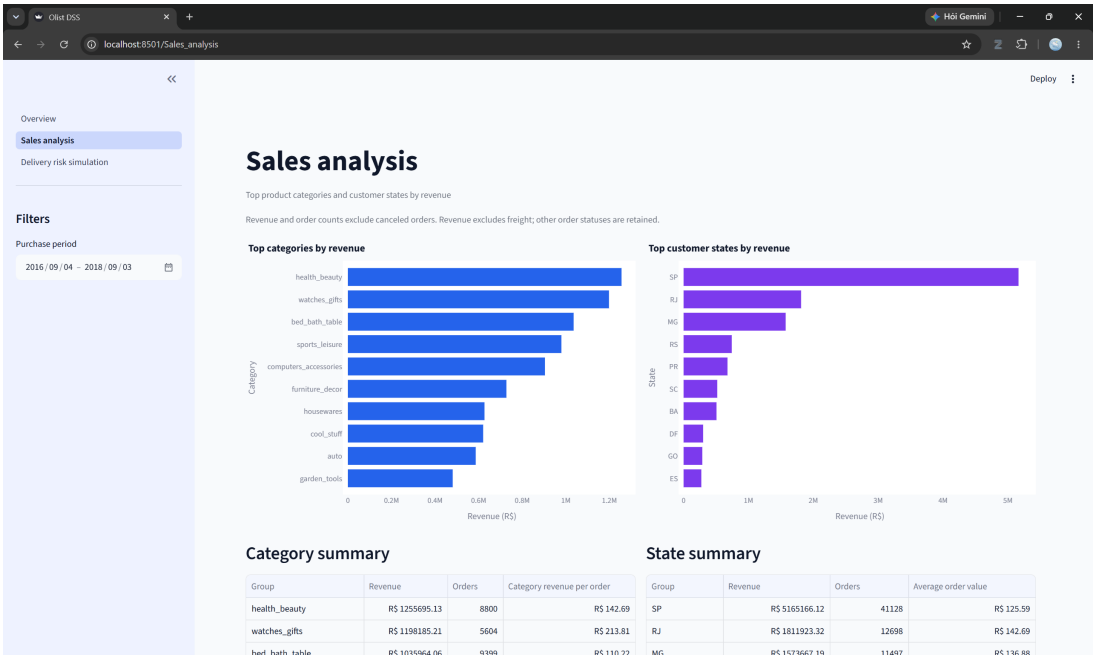
Giao diện phân tích kinh doanh được xây dựng trên nền tảng Streamlit, bao gồm hai trang phân tích chính cung cấp thông tin từ mức tổng quan đến chi tiết: trang overview và sales analysis.

Với toàn bộ khoảng thời gian khả dụng, số liệu từ DB cho thấy doanh thu không gồm đơn hủy là 13,496,408.43 R$, số đơn bán 98,205, AOV 137.43 R$ và tỷ lệ trễ trong tập đủ điều kiện là 6.77%. Trang tích hợp bộ lọc khoảng thời gian mua hàng, cho phép người dùng linh hoạt điều chỉnh khung thời gian phân tích. Bên dưới các thẻ KPI là hai biểu đồ chuỗi thời gian thể hiện biến động doanh thu, số lượng đơn hàng và diễn biến tỷ lệ giao trễ qua các tháng.




Hình 5.1: Giao diện trang overview.

Trang sales analysis hiển thị biểu đồ cột và bảng chi tiết 10 danh mục, cùng 10 bang khách hàng có doanh thu cao nhất trong khoảng ngày chọn.




Hình 5.2: Giao diện trang sale analysis.

## 5.3. Hạn chế

Mặc dù báo cáo cung cấp đầy đủ thông tin cho các câu hỏi phân tích kinh doanh chính, giải pháp hiện tại vẫn tồn tại một số hạn chế kỹ thuật:

– Do đề tài sử dụng trực tiếp cơ sở dữ liệu PostgreSQL cho các truy vấn tổng

hợp mà không triển khai một máy chủ OLAP chuyên biệt (như SSAS hay Mondrian), các phép tính tổng hợp trên tập dữ liệu lớn có thể chịu độ trễ nhất định.
- Hai trang phân tích bán hàng hỗ trợ lọc thời gian và danh sách top 10 cố định, chưa hỗ trợ thao tác drill-down linh hoạt cho từng thành phố hoặc sản phẩm cụ thể.
- Dữ liệu báo cáo mang tính chất lịch sử và tĩnh, chưa được kết nối với luồng dữ liệu cập nhật theo thời gian thực.

# 6. Thiết kế hệ hỗ trợ quyết định và mô hình dự báo

## 6.1. Kiến trúc hệ hỗ trợ quyết định

Hệ hỗ trợ quyết định (DSS) trong hệ thống được thiết kế theo mô hình ba thành phần cốt lõi bao gồm hệ quản trị cơ sở dữ liệu, hệ quản trị mô hình và giao diện tương tác người dùng. Chương trình tạo đặc trưng trích xuất dữ liệu từ kho dữ liệu vào mart.order_delivery_ml_features. Mô hình Logistic Regression được huấn luyện và lưu các thông số tại mart.order_late_risk. Giao diện cho phép chọn nhóm đơn theo bang và năng lực kiểm tra để tạo danh sách ưu tiên trên dữ liệu lịch sử.

## 6.2. Xác định mốc thời gian dự báo và các biến đặc trưng

Để đảm bảo tính hợp lệ của bài toán dự báo rủi ro trong thực tế và tránh hiện tượng rò rỉ dữ liệu, mốc thời gian dự báo được xác định ngay tại thời điểm đơn hàng được xác nhận thanh toán thành công. Tại thời điểm này, các thông tin về quá trình vận chuyển thực tế, ngày giao hàng cho đơn vị vận tải, ngày khách hàng nhận hàng cũng như đánh giá của khách hàng đều chưa xuất hiện và không được đưa vào mô hình.

Nhóm lựa chọn sáu biến đặc trưng tiền vận chuyển có sẵn tại thời điểm dự báo để đưa vào mô hình bao gồm:
- promised_lead_time_days: khoảng thời gian từ lúc phê duyệt đến thời điểm hứa giao, quy đổi sang ngày và làm tròn hai chữ số thập phân.
- item_count: số dòng hàng của đơn trong fact_sales, cũng là số đơn vị sản phẩm do grain của dữ liệu nguồn.
- Tổng giá trị đơn hàng total_order_value bao gồm tiền hàng và cước phí vận chuyển.
- Tháng đặt hàng purchase_month để ghi nhận yếu tố mùa vụ.
- Mã bang của khách hàng customer_state đại diện cho vị trí địa lý của người nhận.

– Cờ xác định có người bán khác bang với khách hàng has_out_of_state_seller.

Biến mục tiêu is_late được lấy từ dw.fact_delivery: TRUE khi ngày giao thực tế sau ngày hứa giao trên lịch, FALSE khi cùng ngày hoặc sớm hơn, và NULL khi không đủ điều kiện. Tập dữ liệu mô hình gồm những đơn có cả is_ml_eligible và is_timeliness_eligible bằng TRUE: đã giao với các mốc hợp lệ, có thời điểm phê duyệt, thời điểm hứa giao không trước phê duyệt và có ít nhất một dòng hàng.

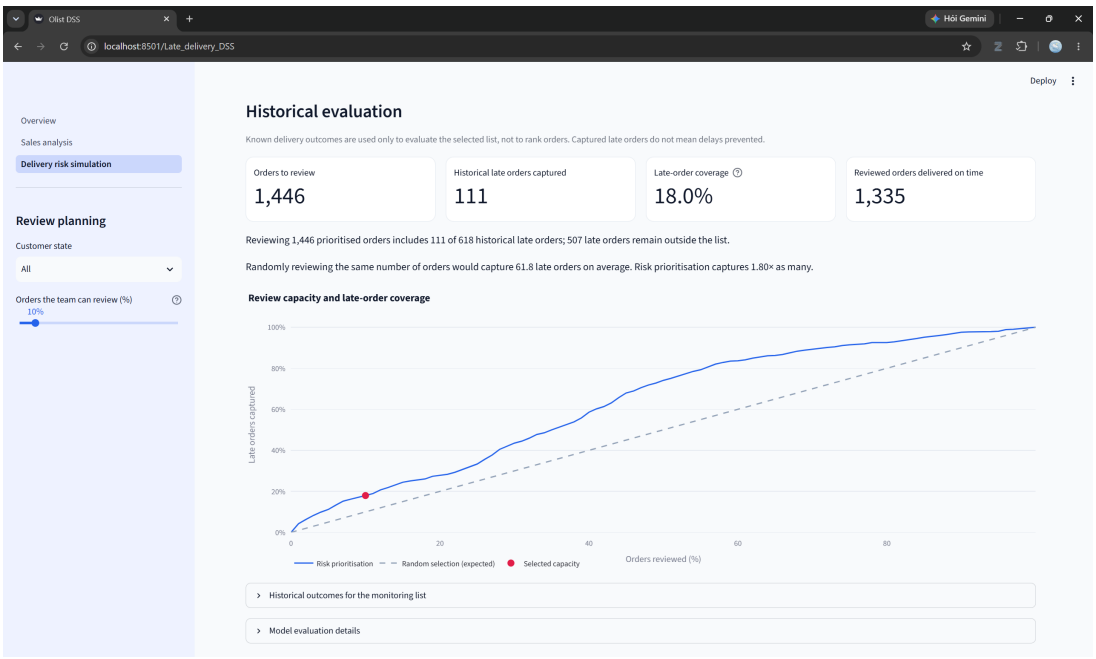
### 6.3. Huấn luyện mô hình và quy trình phân chia dữ liệu

Nhóm chọn Logistic Regression làm mô hình duy nhất nhằm giữ cách xây dựng và diễn giải ở mức phù hợp với phạm vi đề tài. Tập dữ liệu gồm 96,450 đơn hợp lệ được sắp theo ngày mua (purchase_date_key) rồi order_id và chia theo số dòng thành ba tập:

– Tập huấn luyện chiếm 70% đơn hàng sớm nhất theo thời gian (67,515 đơn hàng) dùng để huấn luyện các hệ số của mô hình Logistic Regression.
– Tập kiểm định chiếm khoảng 15% tiếp theo (14,467 đơn), dùng để đánh giá và đặt ngưỡng cố định tại phân vị 90% xác suất dự đoán, cho alert_threshold xấp xỉ 0.0714.
– Tập kiểm thử chiếm khoảng 15% mới nhất (14,468 đơn), không dùng để khớp mô hình hoặc chọn ngưỡng; dùng cho đánh giá hồi cứu và trang mô phỏng DSS.

### 6.4. Thiết kế chức năng mô phỏng khả năng kiểm tra trên Streamlit

Trang delivery risk simulation sử dụng duy nhất tập dữ liệu kiểm thử để đóng vai trò giả lập luồng đơn hàng mới về trong thực tế. Người dùng chọn bang khách hàng và tỷ lệ kiểm tra từ 0% đến 100%, mặc định 10%. Ngân sách bằng số đơn đang lọc nhân tỷ lệ và làm tròn xuống. Hệ thống sắp theo risk_probability giảm dần, dùng order_id tăng dần khi hòa điểm, rồi lấy đúng số đơn đầu danh sách. Chính sách này khác với ngưỡng cảnh báo cố định của mô hình: cùng một ngưỡng xác suất không bảo đảm chọn đúng tỷ lệ ngân sách trên tập kiểm thử.




Hình 6.1: Giao diện trang delivery risk simulation.

Giao diện hiển thị ngay lập tức các chỉ số kết quả kịch bản bao gồm: số đơn hàng cần kiểm tra, số đơn hàng trễ thực tế tìm được trong danh sách kiểm tra, tỷ lệ bắt trúng đơn trễ (recall/coverage), độ chính xác của danh sách rà soát (precision) và chỉ số cải thiện (lift) so với phương pháp lựa chọn ngẫu nhiên. Danh sách các đơn hàng ưu tiên kiểm tra được hiển thị ở bảng phía dưới, giới hạn xem trước 500 dòng để tối ưu hiệu năng giao diện web, đồng thời cung cấp nút tải về toàn bộ danh sách định dạng CSV.

# 7. Kết quả thực nghiệm và đánh giá

## 7.1. Kết quả thực thi các tiến trình ETL và độ chính xác dữ liệu

Ba tiến trình dữ liệu trên Apache Airflow được kích hoạt lần lượt theo thứ tự olist_staging_pipeline, olist_dw_pipeline và olist_ml_features_pipeline. Mỗi DAG điều phối các tác vụ bên trong tiến trình tương ứng; thứ tự thực thi giữa các DAG do người vận hành đảm nhiệm.

Tiến trình olist_staging_pipeline nạp dữ liệu từ 7 tệp CSV vào schema staging, giữ nguyên số lượng bản ghi nguồn. Tiến trình olist_dw_pipeline thực hiện biến đổi và nạp dữ liệu vào kho đa chiều theo cấu trúc Fact Constellation. Bảng dw.fact_sales ghi nhận 112,650 dòng, mỗi dòng đại diện cho một đơn vị sản phẩm trong đơn hàng; bảng dw.fact_delivery ghi nhận 99,441 đơn hàng. Các dòng hàng thuộc đơn bị hủy vẫn được lưu trong kho dữ liệu, nhưng bị loại khỏi phạm vi tính doanh thu và số đơn bán trên dashboard.

Các chỉ số tài chính và thống kê được đối soát với PostgreSQL và các truy vấn phục vụ Streamlit. Bảng 7.1 tổng hợp số liệu trên toàn bộ dữ liệu trong phạm vi hệ thống. Mỗi nhóm chỉ số có tập đơn hàng và mẫu số riêng như mô tả trong bảng.

Bảng 7.1: Tổng hợp các chỉ số thực nghiệm và phạm vi tính toán.

| **Chỉ số đo lường / Đối tượng** | **Giá trị thực nghiệm** | **Phạm vi / Điều kiện áp dụng** |
|---|---|---|
| Tổng doanh thu bán hàng | 13,496,408.43 R$ | Tổng tiền hàng của đơn khác c anceled; không tính freight |
| Tổng số lượng đơn hàng bán | 98,205 đơn hàng | Đếm đơn không bị hủy và có ít nhất một dòng hàng |
| Giá trị trung bình đơn hàng (AOV) | 137.43 R$ | Doanh thu bán hàng / Số đơn hàng bán |
| Tổng số đơn hàng giao thành công | 96,478 đơn hàng | order_status = `delivered` |
| Số đơn hàng hợp lệ tính thời gian | 96,470 đơn hàng | is_timeliness_eligible = `TRUE` |
| Số đơn hàng giao trễ thực tế | 6,534 đơn hàng | is_late = `TRUE` |
| Tỷ lệ giao trễ trong nhóm đủ điều kiện | 6.77% | Số đơn trễ / Số đơn hợp lệ tính thời gian |

Doanh thu trên dashboard chỉ loại trạng thái canceled và giữ các trạng thái khác. Tỷ lệ giao trễ 6.77% được tính trên 96,470 đơn đủ điều kiện.

## 7.2. Đánh giá hiệu năng mô hình dự báo rủi ro

Mô hình Logistic Regression được huấn luyện trên 67,515 đơn hàng đầu tiên theo thứ tự thời gian mua. Tập kiểm định gồm 14,467 đơn tiếp theo được dùng để đánh giá và xác định ngưỡng cảnh báo; tập kiểm thử gồm 14,468 đơn mới nhất được dùng cho giao diện mô phỏng.

Tập kiểm thử có 618 đơn giao trễ trên tổng số 14,468 đơn, tương ứng 4.27%. Vì vậy, độ chính xác tổng thể accuracy không được dùng làm tiêu chí đánh giá chính: một phương pháp luôn dự đoán đúng hạn có thể đạt accuracy cao nhưng không phát hiện được đơn trễ. Nhóm sử dụng ROC-AUC, PR-AUC, brier score và tỷ lệ bao phủ đơn trễ tại một ngân sách rà soát cố định. Average precision được tính trực tiếp từ hàm đánh giá của scikit-learn.

Bảng 7.2: Kết quả đánh giá Logistic Regression trên tập kiểm định và tập kiểm thử.

| **Tập dữ liệu** | **PR-AUC** | **ROC-AUC** | **Brier score** | **Recall khi rà soát top 10%** |
|---|---|---|---|---|
| Tập kiểm định | 0.1094 | 0.7203 | 0.0403 | 31.90% |
| Tập kiểm thử | 0.0754 | 0.6431 | 0.0407 | 17.96% |

Trên tập kiểm thử, mô hình có ROC-AUC 0.6431 và average precision 0.0754, cho thấy khả năng ưu tiên rủi ro còn khiêm tốn. Hiệu quả trên tập kiểm thử thấp hơn tập kiểm định, phản ánh hạn chế về khả năng tổng quát hóa giữa các giai đoạn. Các biến tiền vận chuyển hiện có cung cấp một phần tín hiệu rủi ro, nhưng chưa đủ bằng chứng để quy toàn bộ nguyên nhân của cho bộ biến hiện tại.

Ngưỡng cảnh báo rủi ro cố định alert_threshold = 0.0714 được xác định từ phân vị 90% của xác suất dự đoán trên tập kiểm định. Khi áp dụng ngưỡng này trên tập kiểm thử, mô hình đánh dấu 1,848 đơn hàng cần cảnh báo, trong đó có 133 đơn giao trễ trên tổng số 618 đơn giao trễ thực tế. Kết quả đạt recall 21.52% và precision 7.20%, với chỉ số lift khoảng 1.68 lần so với lựa chọn ngẫu nhiên cùng số lượng đơn hàng.

### 7.3. Đánh giá kịch bản phân bổ nguồn lực kiểm tra

Chức năng mô phỏng trên Streamlit đánh giá việc ưu tiên kiểm tra theo xác suất rủi ro dự đoán trên tập kiểm thử lịch sử. Với mỗi mức năng lực, số đơn rà soát được tính bằng tổng số đơn trong nhóm đang lọc nhân với tỷ lệ kiểm tra và làm tròn xuống. Danh sách được sắp xếp theo risk_probability giảm dần, dùng o rder_id tăng dần để phân xử khi xác suất bằng nhau.

Bảng 7.3 sử dụng toàn bộ 14,468 đơn của tập kiểm thử, với 618 đơn giao trễ thực tế. Recall là số đơn trễ trong danh sách chia cho 618; precision là số đơn trễ trong danh sách chia cho số đơn rà soát. Lift bằng precision chia cho tỷ lệ trễ nền 4.27%, được tính bằng tỷ lệ đầy đủ trước khi làm tròn. Phương pháp ngẫu nhiên được biểu diễn bằng kết quả kỳ vọng khi chọn cùng số lượng đơn hàng.

Bảng 7.3: Kết quả mô phỏng phân bổ nguồn lực kiểm tra trên tập kiểm thử.

| Tỷ lệ kiểm tra | Số đơn rà soát | Số đơn trễ tìm được | Recall | Precision | Lift |
|---|---|---|---|---|---|
| 5% | 723 | 69 | 11.17% | 9.54% | 2.23× |
| 10% | 1,446 | 111 | 17.96% | 7.68% | 1.80× |
| 15% | 2,170 | 151 | 24.43% | 6.96% | 1.63× |
| 20% | 2,893 | 172 | 27.83% | 5.95% | 1.39× |
| 25% | 3,617 | 206 | 33.33% | 5.70% | 1.33× |
| 50% | 7,234 | 458 | 74.11% | 6.33% | 1.48× |
| 100% | 14,468 | 618 | 100.00% | 4.27% | 1.00× |

Kết quả cho thấy lợi ích ưu tiên rủi ro đi kèm giới hạn về số đơn trễ được bao phủ:

– Tại mức kiểm tra 5% (723 đơn), danh sách chứa 69 đơn trễ, đạt recall 11.17%, precision 9.54% và lift khoảng 2.23 lần so với lựa chọn ngẫu nhiên

cùng ngân sách.

- Tại mức kiểm tra 10% (1,446 đơn), danh sách chứa 111 đơn trễ, tương ứng 17.96% tổng số đơn trễ trong tập kiểm thử. Lựa chọn ngẫu nhiên cùng số lượng có kỳ vọng tìm được khoảng 61.77 đơn trễ, nên lift đạt khoảng 1.80 lần. Tuy nhiên, 1,335 đơn được chọn thực tế giao đúng hạn và còn 507 đơn trễ nằm ngoài danh sách.
- Tại mức kiểm tra 20% (2,893 đơn), danh sách chứa 172 đơn trễ, đạt recall 27.83%, precision 5.95% và lift khoảng 1.39 lần. Việc tăng năng lực giúp bao phủ thêm đơn trễ, đồng thời làm tăng số đơn phải kiểm tra nhưng thực tế giao đúng hạn.

Như vậy, mô hình cung cấp khả năng ưu tiên rủi ro có cải thiện so với lựa chọn ngẫu nhiên trong các kịch bản lịch sử đã đánh giá, nhưng hiệu quả còn hạn chế. Danh sách kiểm tra là công cụ hỗ trợ nhân viên xác minh tiến độ và cam kết giao hàng.

# 8. Hạn chế, hướng phát triển và kết luận

## 8.1. Những kết quả đạt được của đề tài

Đề tài đã hiện thực các thành phần cốt lõi của một hệ thống kho dữ liệu kết hợp hỗ trợ quyết định trên bộ dữ liệu lịch sử Olist. Các kết quả chính gồm:

- Xây dựng kho đa chiều Fact Constellation trên PostgreSQL từ 7 tệp nguồn, gồm 4 bảng dim và 2 bảng fact fact_sales, fact_delivery.
- Đóng gói các bước nạp, chuyển đổi và kiểm tra dữ liệu thành tác vụ Airflow.
- Phát triển giao diện báo cáo phân tích kinh doanh đa chiều trên Streamlit, giải quyết được các câu hỏi nghiệp vụ về theo dõi xu hướng doanh thu, cơ cấu sản phẩm, thị trường địa lý và biến động tỷ lệ giao trễ theo thời gian.
- Tích hợp một mô hình Logistic Regression và mô phỏng phân bổ năng lực rà soát trên tập kiểm thử. Khi chọn 10% đơn (1,446 đơn), danh sách chứa 111 trong 618 đơn giao trễ, tương ứng coverage 17.96% và precision 7.68%. Số đơn trễ tìm được bằng khoảng 1.80 lần kỳ vọng của lựa chọn ngẫu nhiên cùng ngân sách.

## 8.2. Hạn chế còn tồn tại

Bên cạnh những kết quả đạt được, hệ thống hiện tại vẫn ghi nhận một số hạn chế kỹ thuật và phạm vi nghiệp vụ cần được cải thiện:

- Dữ liệu là mẫu lịch sử tĩnh, chưa có luồng đơn đang vận chuyển hoặc cơ chế nạp định kỳ. Danh sách ưu tiên là kết quả mô phỏng, không phải danh sách tác nghiệp trực tiếp.

- Mô hình dự báo rủi ro mới chỉ khai thác các thuộc tính tĩnh tiền vận chuyển tại thời điểm xác nhận đơn hàng mà chưa tích hợp được các dữ liệu chuỗi hành trình vận chuyển động phát sinh trong quá trình giao hàng.
- Hiệu quả ưu tiên còn hạn chế: tại ngân sách 10%, 507 đơn trễ nằm ngoài danh sách và 1,335 đơn được rà soát thực tế đúng hạn. Recall ở cùng ngân sách giảm từ 31.90% trên tập kiểm định xuống 17.96% trên tập kiểm thử, cho thấy hiệu năng thay đổi theo giai đoạn. Brier score hiện có chưa đủ để khẳng định xác suất được hiệu chỉnh tốt.
- Cách chia theo thứ tự ngày mua và số dòng có thể đặt các đơn cùng ngày biên vào hai tập khác nhau. Đề tài chưa bảo đảm mọi nhãn huấn luyện đã sẵn có tại một thời điểm triển khai mô phỏng. Tập mô hình chỉ gồm đơn đủ điều kiện có kết quả giao hàng, nên chưa đại diện đầy đủ cho mọi đơn mở hoặc chưa giải quyết trong thực tế.
- Giao diện chưa có phân quyền người dùng, lưu lịch sử kịch bản hoặc drill-down linh hoạt đến từng thành phố/sản phẩm. Đề tài chưa đo tác động của hành động kiểm tra, chi phí tiết kiệm hoặc số đơn trễ được ngăn chặn.

### 8.3. Hướng phát triển trong tương lai

Để nâng cao hơn nữa giá trị thực tiễn và khả năng mở rộng của hệ thống, nhóm đề xuất một số hướng phát triển trọng tâm trong tương lai bao gồm:

- Bổ sung và đánh giá các biến hợp lệ tại cùng mốc dự báo như trọng lượng/thể tích sản phẩm, số người bán, vùng người bán hoặc khoảng cách khách hàng–người bán khi có ánh xạ địa lý đáng tin cậy. Chỉ giữ các biến hoặc tương tác giúp cải thiện kết quả trên tập kiểm định.
- Đánh giá mô hình qua nhiều cửa sổ thời gian và chỉ dùng nhãn đã biết trước mốc đánh giá. Theo dõi tỷ lệ trễ, chất lượng xếp hạng và mức khớp giữa xác suất dự đoán với tần suất trễ thực tế.
- Bổ sung chi phí rà soát và lợi ích khi phát hiện đúng để so sánh năng lực kiểm tra theo mục tiêu nghiệp vụ. Khi có nguồn đơn mới, xác định lịch nạp và chấm điểm phù hợp, điều phối đầy đủ chuỗi tác vụ và quản lý phiên bản kết quả. Xem xét tích hợp xử lý dữ liệu theo thời gian thực.
- Thử nghiệm di chuyển tầng kho dữ liệu sang các nền tảng Data Lakehouse hoặc Cloud Data Warehouse chuyên dụng để nâng cao hiệu năng truy vấn OLAP phức tạp trên tập dữ liệu lớn.
- Hoàn thiện giao diện người dùng bằng cách bổ sung tính năng quản lý tài khoản, cho phép xuất báo cáo tùy chỉnh định dạng PDF/Excel và lưu trữ lịch sử quyết định kiểm tra của đội ngũ vận hành để phục vụ công tác đánh giá hiệu quả sau kiểm tra.

## 8.4. Kết luận

Nghiên cứu đã hiện thực thành công luồng xử lý dữ liệu toàn diện từ dữ liệu nguồn qua staging, kho đa chiều, feature mart cho đến giao diện phân tích và hỗ trợ lựa chọn đơn ưu tiên. Mặc dù các kết quả đối soát xác nhận tính nhất quán của dữ liệu, mô hình Logistic Regression chỉ mới đạt hiệu quả ở mức khiêm tốn so với lựa chọn ngẫu nhiên cùng năng lực, cho thấy mô hình hiện tại dừng lại ở bước đầu thử nghiệm. Tuy nhiên, hệ thống đã bước đầu đáp ứng mục tiêu minh họa mối liên hệ giữa kho dữ liệu, phân tích đa chiều và hệ hỗ trợ quyết định trong phạm vi bài tập lớn. Tổng thể, đề tài phần nào chứng minh tính khả thi của việc kết hợp kiến trúc kho dữ liệu đa chiều với học máy trong vận hành thương mại điện tử, cung cấp cho nhà quản lý một công cụ hỗ trợ tác nghiệp tiềm năng để từng bước tối ưu hóa chi phí kiểm tra và chất lượng dịch vụ giao hàng, đồng thời tạo cơ sở cho các hướng mở rộng quy mô hơn trong thực tế.