ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA

KHO DỮ LIỆU VÀ HỆ HỖ TRỢ QUYẾT ĐỊNH

KHO DỮ LIỆU VÀ HỆ HỖ TRỢ QUYẾT ĐỊNH
PHÂN TÍCH DOANH SỐ VÀ RỦI RO GIAO HÀNG

GVHD:	Đỗ Thanh Thái
Nhóm 11:	Võ Lâm Gia Bảo - 2310273
	Nguyễn Hữu Thiên Cường - 2310393
	Đặng Hải Sơn - 2312955

Nội dung chính

1. Giới thiệu đề tài
2. Giới thiệu bộ dữ liệu
3. Thiết kế kho dữ liệu
4. Mô hình và đánh giá rủi ro
5. Khai thác kho dữ liệu

1

Giới thiệu đề tài

1

Giới thiệu đề tài

Bài toán và mục tiêu

- **Doanh thu và số đơn biến động thế nào theo thời gian?**

  Theo dõi doanh thu và số đơn theo thời gian, danh mục sản phẩm và bang khách hàng.

- **Danh mục và bang nào đóng góp nhiều doanh thu nhất?**

  Xếp hạng doanh thu theo danh mục sản phẩm và bang khách hàng.

- **Tỷ lệ giao trễ thay đổi thế nào?**

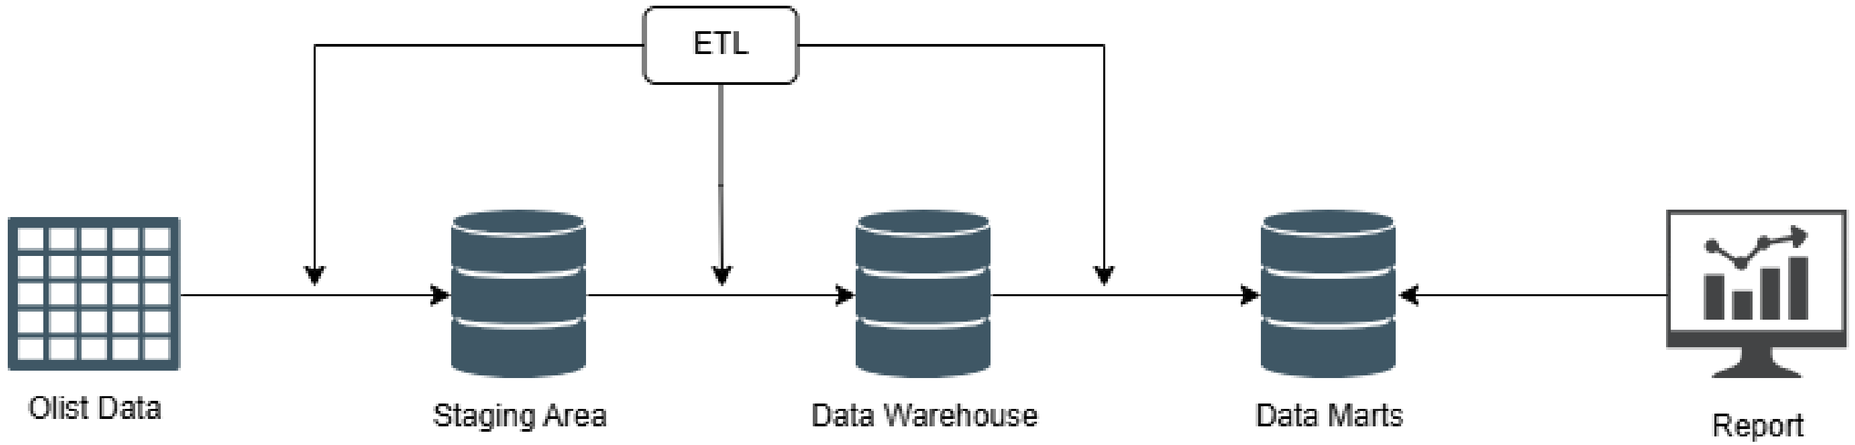
  Theo dõi tỷ lệ giao trễ theo tháng trên các đơn đã giao và đủ thông tin thời gian.

- **Nên rà soát đơn nào trước khi nguồn lực có hạn?**

  Xếp hạng đơn lịch sử theo rủi ro dự đoán và mô phỏng danh sách ưu tiên theo năng lực kiểm tra.

1

Giới thiệu đề tài
Kiến trúc tổng thể



2

Giới thiệu bộ dữ liệu

2

Giới thiệu bộ dữ liệu
Bộ dữ liệu Olist

Nguồn dữ liệu

Bộ dữ liệu thương mại điện tử Brazil của Olist giai đoạn 2016-2018

https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce

Quy mô

99.441 đơn hàng

Phạm vi

Sử dụng 7/9 tệp CSV

	A	B	C	D	E
1	customer_	customer_	customer_	customer_	customer_
2	06b8999e:	861eff471	14409	franca	SP
3	18955e83(	290c77bc5	9790	sao berna	SP
4	4e7b3e00:	060e732b5	1151	sao paulo	SP
5	b2b6027b	259dac757	8775	mogi das c	SP
6	4f2d8ab17	345ecd01c	13056	campinas	SP
7	879864dal	4c9374451	89254	jaragua dc	SC
8	fd826e7cf	addec96d2	4534	sao paulo	SP
9	5e274e7a(	57b2a98a4	35182	timoteo	MG
10	5adf08e34	1175e95fb	81560	curitiba	PR
11	4b7139f34	9afe194fb	30575	belo horiz	MG
12	9fb35e4ec	2a7745e1e	39400	montes cla	MG
13	5aa9e4fdc	2a46fb94a	20231	rio de jane	RJ
14	b2d15365'	918dc87cc	18682	lencois pa	SP
15	eabebad3	295c05e81	5704	sao paulo	SP
16	1f1c7bf1c5	3151a818(	95110	caxias do s	RS
17	206f3129c	21f748a16	13412	piracicaba	SP
18	a7c125a0a	5c2991db0	22750	rio de jane	RJ
19	c5c61596a	b6e99561f	7124	guarulhos	SP
20	9b8ce803(	7f3a72e8f	5416	sao paulo	SP
21	49d0ea09:	3e6fd6b2f	68485	pacaja	PA

3

Thiết kế kho dữ liệu

3

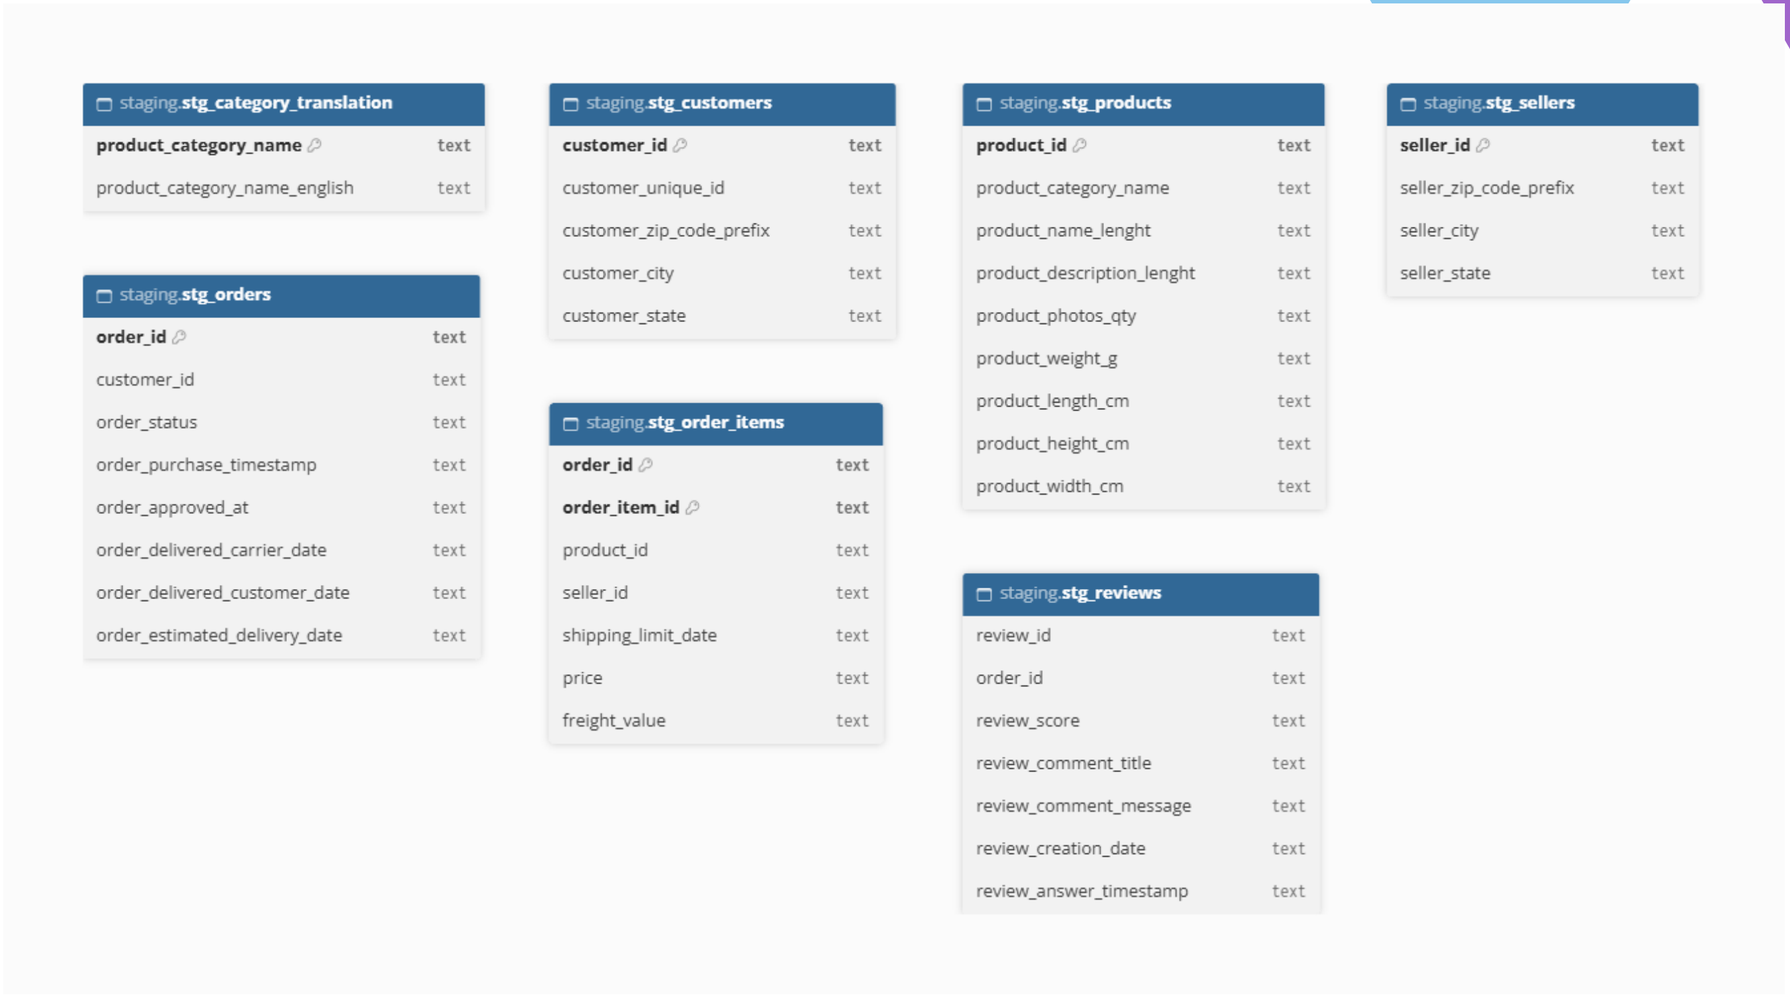
Thiết kế kho dữ liệu
Quy trình ETL

- Apache Airflow là công cụ mã nguồn mở dùng để điều phối và theo dõi các quy trình xử lý dữ liệu.
- Mỗi quy trình được mô tả bằng một DAG, xác định thứ tự và sự phụ thuộc giữa các tác vụ.
- Nhóm dùng ba DAG để nạp dữ liệu nguồn vào Staging Area, xây dựng Data Warehouse và tạo Data Mart cho mô hình dự đoán giao trễ.



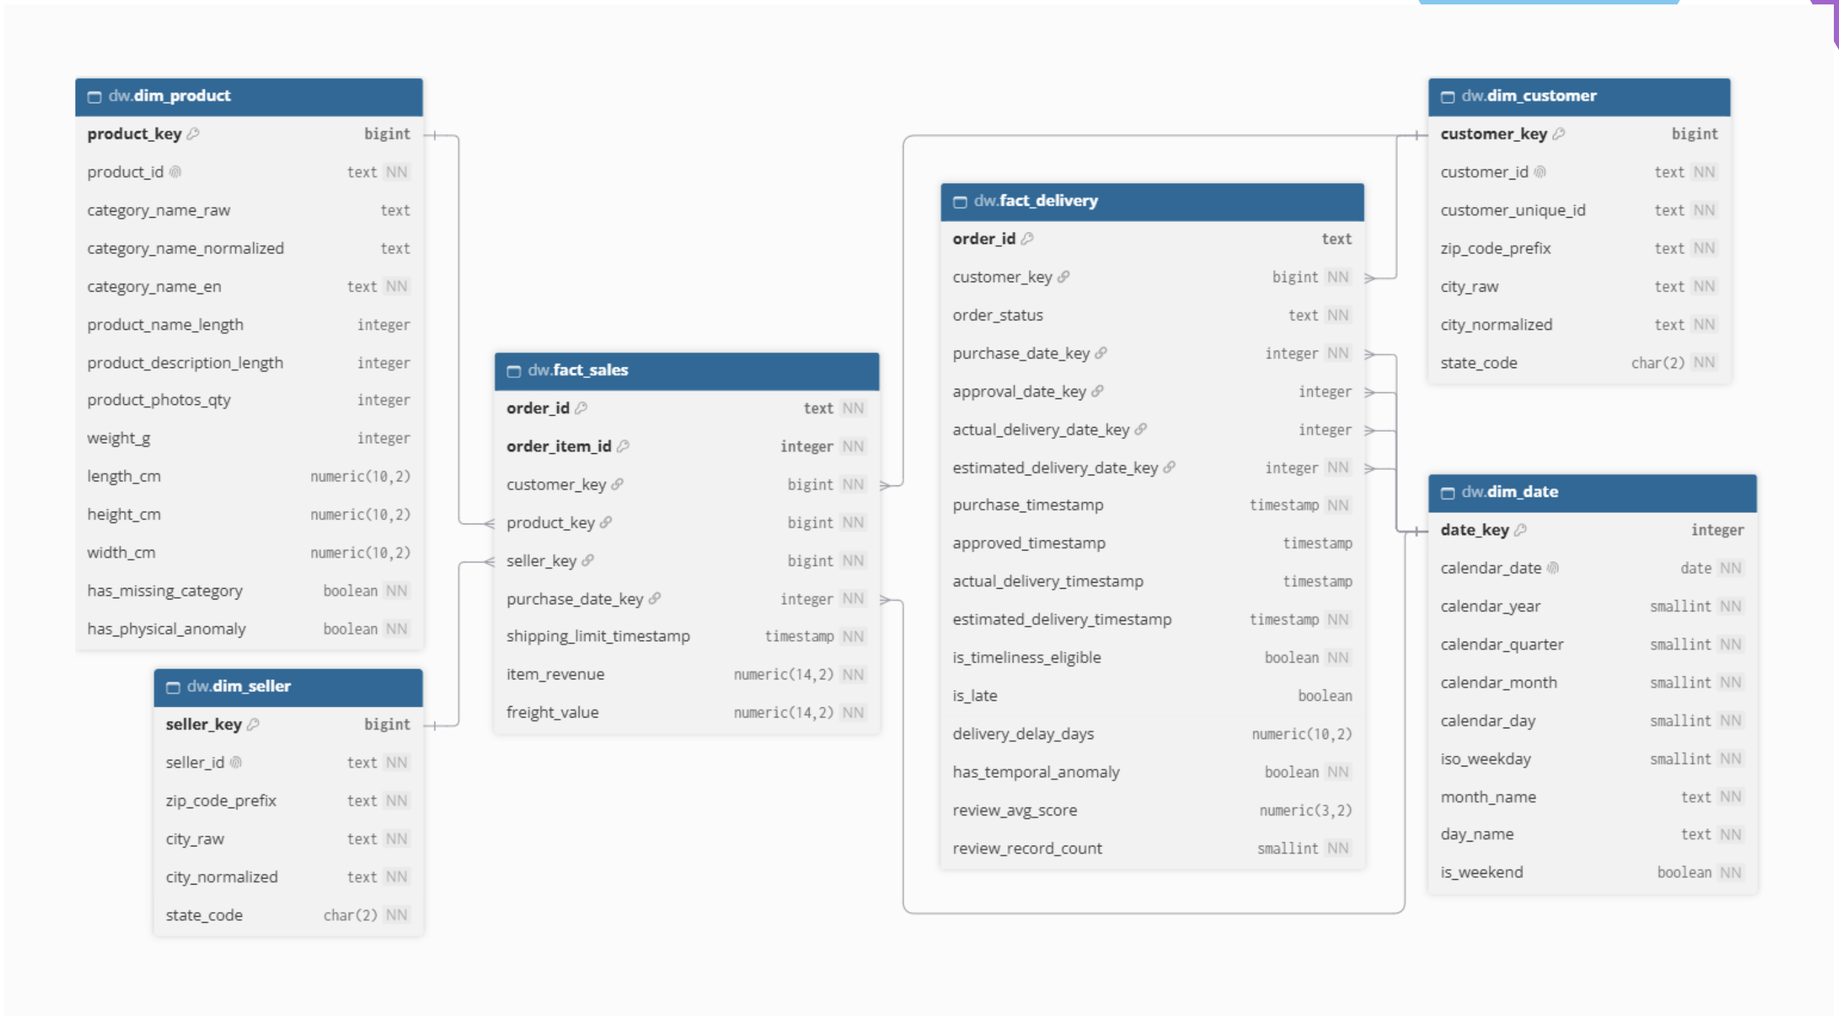
3

Thiết kế kho dữ liệu
Staging Area



3

Thiết kế kho dữ liệu
Lược đồ kho dữ liệu



4

Mô hình và đánh giá rủi ro

4

Mô hình và đánh giá

Data mart cho mô hình



- Mỗi đơn một dòng: số sản phẩm (item_count) và tổng tiền hàng cộng cước (total_order_value), gom từ fact_sales.
- Nhãn is_late và các cờ điều kiện lấy trực tiếp từ fact_delivery, không tính lại.
- Chỉ đơn có ngày phê duyệt, hứa giao không trước phê duyệt và có ít nhất một sản phẩm mới đủ điều kiện huấn luyện.
- validate_features.py kiểm tra 6 quy tắc: số dòng, grain, đối soát tiền, nhãn, đặc trưng và cột kết quả.

4

Mô hình và đánh giá

Mốc dự báo và đặc trưng

Có thể dùng khi dự báo | **Chưa biết khi dự báo**

Đặt hàng → **Xác nhận thanh toán** ← *mốc dự báo* → Bàn giao vận chuyển → Giao hàng thực tế → Khách đánh giá

promised_lead_time_days Số ngày từ phê duyệt đến ngày hứa giao	**item_count** Số dòng hàng trong đơn	**total_order_value** Tiền hàng cộng cước	**purchase_month** Tháng mua, phản ánh mùa vụ	**customer_state** Bang của khách hàng	**has_out_of_state_seller** Người bán khác bang khách

Loại khỏi mô hình (chỉ biết sau khi giao): ngày giao thực tế, số ngày trễ, trạng thái cuối, sự kiện vận chuyển, điểm đánh giá.

4

Mô hình và đánh giá
Logistic Regression

1

Tiền xử lý
Điền giá trị thiếu: trung vị với số, giá trị phổ biến với nhóm. Chuẩn hóa số bằng RobustScaler.

2

Mã hóa
Biến nhóm như bang và tháng được mã hóa one-hot thành các cột 0 và 1.

3

Tính điểm
Cộng có trọng số các đặc trưng, rồi đưa qua hàm sigmoid để được giá trị từ 0 đến 1.

4

Kết quả
Xác suất trễ cho từng đơn. Đây không phải là phán quyết trễ hay đúng hạn.

Chia theo thời gian mua hàng (sớm → muộn)



- Huấn luyện chỉ dùng tập train; validation chọn ngưỡng; test chỉ dùng để đánh giá cuối cùng.
- Chia theo thời gian mô phỏng việc dự báo đơn tương lai từ dữ liệu quá khứ, tránh đánh giá lạc quan.

4

Mô hình và đánh giá

Ngưỡng và chỉ số đánh giá

NGƯỠNG CẢNH BÁO

0,0714

Là phân vị 90% của xác suất dự đoán trên tập validation. Đơn có xác suất từ 0,0714 trở lên được gắn nhãn high, khoảng 10% đơn.
Nhãn high là cảnh báo, không phải kết luận trễ: trong nhóm này chỉ 7,2% đơn trễ, so với 4,27% của toàn tập test.
Ngưỡng được giữ cố định khi áp lên test, nên 1.848 đơn (12,8%) vượt ngưỡng.

Chỉ số	Ý nghĩa	Validation	Test
PR-AUC	Mức xếp đơn trễ lên đầu danh sách. Mốc ngẫu nhiên là 0,043	0,1094	0,0754
ROC-AUC	Khả năng phân biệt đơn trễ và đúng hạn. 0,5 là đoán ngẫu nhiên	0,7203	0,6431
Brier	Sai lệch của xác suất, càng thấp càng tốt. Đoán hằng số khoảng 0,041	0,0403	0,0407
Recall top 10%	Tỷ lệ đơn trễ bắt được trong 10% đơn xếp đầu	31,90%	17,96%

Không dùng accuracy vì nhãn rất hiếm: mô hình luôn đoán "đúng hạn" sẽ đạt 95,7% accuracy nhưng không bắt được đơn trễ nào.

4

Mô hình và đánh giá
Kịch bản phân bổ kiểm tra

111 / 618
đơn trễ bắt được khi kiểm tra 1.446 đơn (10%)

1,80×
lift so với chọn ngẫu nhiên, kỳ vọng 61,77 đơn trễ

507
đơn trễ nằm ngoài danh sách; 1.335 đơn kiểm tra thực tế đúng hạn

Tỷ lệ kiểm tra	Số đơn rà soát	Đơn trễ tìm được	Recall	Precision	Lift
5%	723	69	11,17%	9,54%	2,23×
10%	**1.446**	**111**	**17,96%**	**7,68%**	**1,80×**
15%	2.170	151	24,43%	6,96%	1,63×
20%	2.893	172	27,83%	5,95%	1,39×
25%	3.617	206	33,33%	5,70%	1,33×
50%	7.234	458	74,11%	6,33%	1,48×
100%	14.468	618	100%	4,27%	1,00×

Recall = đơn trễ bắt được / 618. Precision = đơn trễ bắt được / số đơn rà soát. Lift = precision / 4,27%.

Kiểm tra càng nhiều thì recall càng tăng, nhưng precision giảm dần: lợi ích của mô hình thu hẹp khi năng lực kiểm tra tăng.

4

Mô hình và đánh giá
Hạn chế và cách trình bày

Chỉ dùng thông tin lúc thanh toán
Mô hình không biết chuỗi vận chuyển, khoảng cách hay số người bán. Điều này giới hạn sức mạnh dự báo.

Nhãn có thể chưa đủ thời gian
Khi huấn luyện, nhãn của mọi đơn đã có. Trong thực tế, đơn mới mua có thể chưa có kết quả, nên đánh giá có thể lạc quan.

Hiệu năng không ổn định
Recall top 10% là 31,90% trên validation nhưng 17,96% trên test. Nguyên nhân chưa được xác định.

Chưa so với quy tắc đơn giản
Mô hình mới được so với chọn ngẫu nhiên. Chưa đo chi phí kiểm tra hay số đơn trễ thực sự được ngăn chặn.

Cách trình bày: xếp hạng ưu tiên tốt hơn ngẫu nhiên ở mức khiêm tốn, không phải dự đoán chính xác đơn nào sẽ trễ.

4

Mô hình và đánh giá
Kết luận phần mô hình

1

Data mart đúng grain, đối soát được với kho và không chứa thông tin của tương lai.

2

Logistic Regression xếp hạng đơn tốt hơn chọn ngẫu nhiên, với lift 1,80× khi kiểm tra 10% đơn.

3

Đây là công cụ hỗ trợ ưu tiên kiểm tra, không thay thế đánh giá của con người.

1,80×

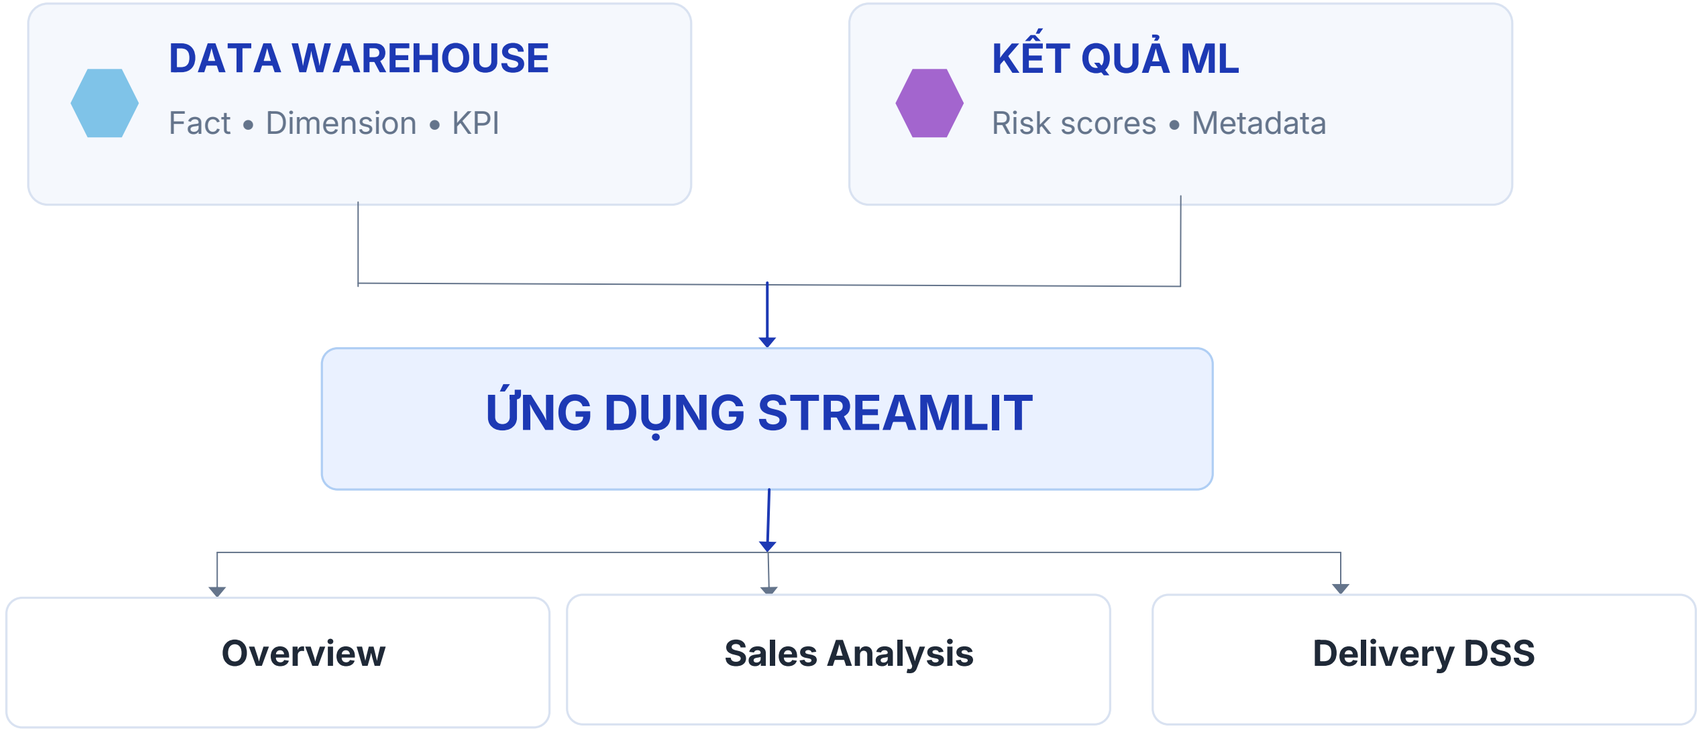
lift khi kiểm tra 10% đơn: bắt được 111 trên 618 đơn trễ

Hướng phát triển: thêm đặc trưng có sẵn tại thời điểm dự báo, đánh giá trên nhiều cửa sổ thời gian và so sánh với quy tắc đơn giản.

5

Khai thác kho dữ liệu
Kiến trúc Dashboard và DSS

TỪ DỮ LIỆU ĐẾN THÔNG TIN RA QUYẾT ĐỊNH



Truy xuất tập trung

KPI và dữ liệu rủi ro đến từ nguồn đã chuẩn hóa.

Phân tích trực quan

Lọc, so sánh doanh thu và xu hướng giao hàng.

Hỗ trợ quyết định

Xếp hạng đơn cần theo dõi theo nguồn lực hiện có.

Data Warehouse → Analytics Dashboard + Delivery Risk Decision Support

5

Khai thác kho dữ liệu
Tổng quan hoạt động kinh doanh



4 chỉ số chính

Revenue, Orders, AOV và tỷ lệ giao trễ.

Theo dõi xu hướng

Doanh thu và số đơn được nhóm theo tháng mua.

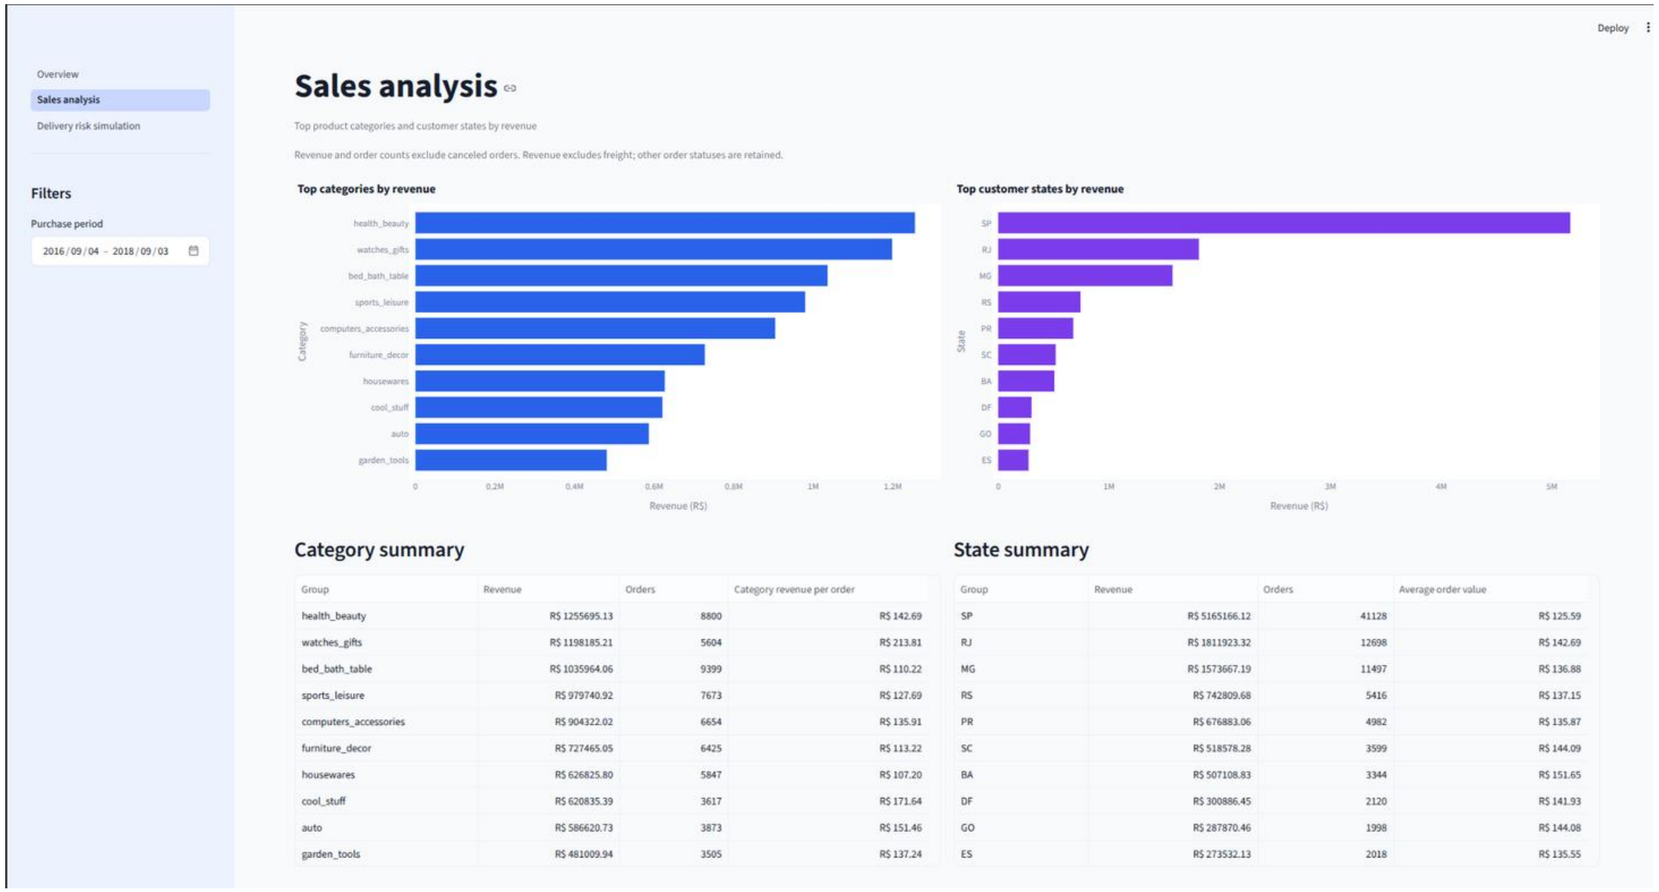
Tính đúng mức dữ liệu

Doanh thu ở cấp item; giao trễ ở cấp đơn hàng.

Số liệu hiển thị từ screenshot lịch sử; Revenue không gồm phí vận chuyển.

5

Khai thác kho dữ liệu
Doanh thu theo danh mục và khu vực



Theo danh mục

Ghép doanh số với chiều sản phẩm; nhóm đứng đầu: health_beauty.

Theo địa lý

Ghép doanh số với chiều khách hàng; bang SP đứng đầu.

Lưu ý khi đọc

Top 10 không phải toàn bộ; một đơn có thể thuộc nhiều category.

Cùng một bảng sự kiện bán hàng được phân tích qua nhiều chiều khác nhau.

5 Khai thác kho dữ liệu
Ưu tiên đơn hàng theo capacity

QUY TRÌNH CHỌN TOP-N

1 **Điểm rủi ro** → 2 **Lọc theo bang** → 3 **Xếp hạng** → 4 **Chọn Top-N**



- **Data: 14.468**
- **Đơn trễ: 618**

SO SÁNH CÙNG NGÂN SÁCH KIỂM TRA 10%

Số đơn trễ nằm trong danh sách được chọn

Chọn ngẫu nhiên (kỳ vọng) — **61,8**

Ưu tiên bằng ML (thực tế) — **111**

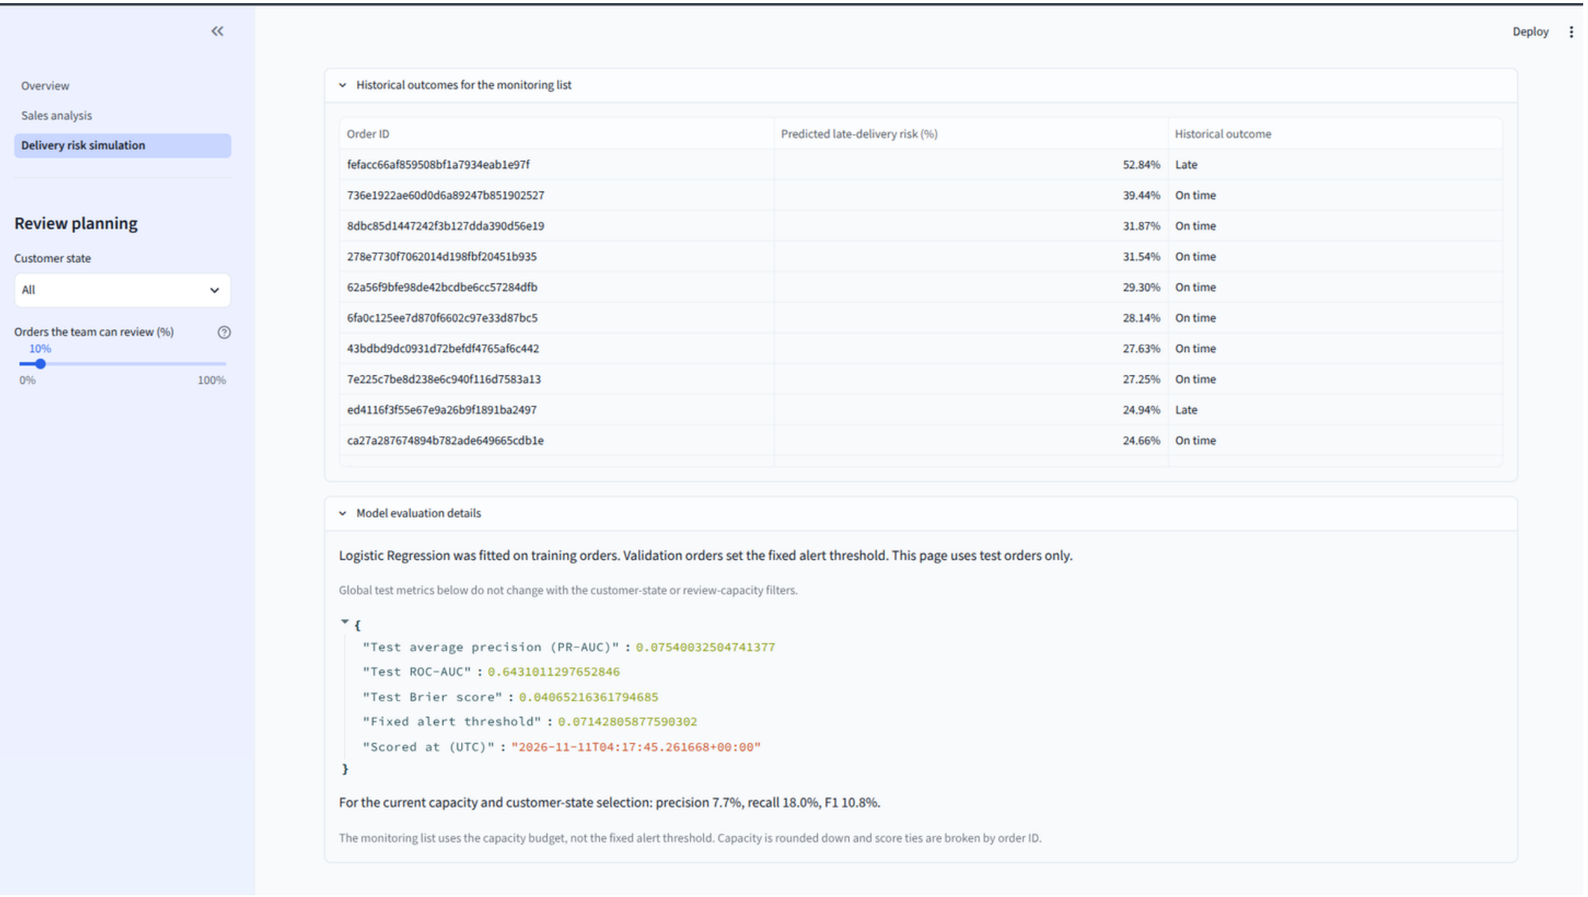
Nguồn: kết quả test lịch sử trong Olist DSS

- **Lift ≈ 1,80×**

5

Khai thác kho dữ liệu

Đánh giá mô hình dự đoán giao trễ



CHỈ SỐ ĐÁNH GIÁ

Precision / Recall / F1: tại capacity 10% trên tập test.

7,7%	**Precision** Chỉ khoảng 8/100 đơn được chọn thực sự trễ.
18,0%	**Recall** Tìm được khoảng 18/100 đơn trễ toàn tập.
10,8%	**F1-score** Thấp vì cả precision và recall đều thấp.

NHẬN XÉT

Hiệu quả dự báo còn thấp một phần do đơn trễ chỉ ~4,3% và thông tin đầu vào còn hạn chế.
Tuy nhiên, Lift 1,80× cho thấy vẫn có ích để ưu tiên kiểm tra.

- **Historical outcomes for the monitoring list:** Hiển thị các đơn được ưu tiên kiểm tra, kèm điểm rủi ro dự đoán và kết quả giao hàng thực tế (Late/On time) để đối chiếu.
- **Model evaluation details:** Hiển thị thông tin mô hình, ngưỡng cảnh báo và các chỉ số đánh giá để kiểm tra hiệu quả dự báo.

CẢM ƠN MỌI NGƯỜI ĐÃ LẮNG NGHE